الجمهورية العربية السورية
كلية الهندسة الميكانيكية والكهربائية
جامعة دمشق
قسم الهندسة الطبية

DL-CIDEA

Deep Learning for Cardiac Ischemia Detection via ECG Analysis

جهاز للكشف عن الإقفار القلبي باستخدام تقنيات التعلم العميق بالاعتماد على تحليل مخطط القلب الكهربائي.

دراسة أعدت كمشروع تطبيقي للسنة الرابعة

إعـداد الطـلاب:

محمد الشيخ حسين
محمد عبد الرحمن
سعيد محمد عزية
هبه خالد طيب

إشراف:

د. هاني عماشة

العام الدراسي:

2025-2024

بسم الله الرحمن الرحيم

كلمة الشكر

إلى من كان لهم الفضل بعد الله تعالى في إتمام هذا العمل، نهدي ثمرة جهدنا وتعب الأيام، إلى كلية الهندسة الميكانيكية والكهربائية التي منحتنا البيئة الأكاديمية الغنية بالعلم والخبرة.

إلى قسم الهندسة الطبية الذي فتح لنا آفاق التخصص والبحث في مجال يجمع بين الهندسة والطب لخدمة الإنسان.

إلى أستاذنا الفاضل الدكتور المشرف هاني عماشة، الذي كان لنا الموجّه والداعم، بفضل توجيهاته السديدة ونصائحه القيّمة والتي ساعدتنا في إنجاز هذا العمل.

وإلى كل من ساندنا بكلمة أو دُعاء أو نصيحة صادقة، نهدي هذا الجهد المتواضع عربون شكر وامتنان.

الإهداء

إلى من كانوا السند الذي أعانني في رحلتي..

إلى من كانوا نور دربي .. أهديكم ثمرة جهدي المتواضع

عائلتي

إلى أساتذتي الأفاضل الذين ساعدوني في هذا المشروع..

بما قدموه من علمٍ ونصحٍ وتوجيه كريم، سيبقى أثرهم ممتداً ما حييت

الدكتور خالد بكور.. الدكتورة نزان الغانم

إلى أصدقائي الأعزاء..

يا من شاركني الطريق.. وكانوا العون والسند في هذا المشروع

المهندس عمر الكوسى.. المهندس سلمان القاسم.. المهندس أحمد ديب

المهندسة حنين الناصر.. المهندسة رغد صالح.. المهندسة راما عرابي

سعيد محمد عزية

إلى والدي العزيز.. الذي كان لي قدوةً في الصبر والعطاء..

وسنداً في كل مراحل حياتي.. فله كل الامتنان والتقدير

والدي

إلى والدتي الغالية.. نبع الحنان ومصدر القوة..

التي لم تبخل بدعائها وتشجيعها.. فكانت الدافع الأكبر لمواصلة الطريق

والدتي

إلى إخوتي الأعزاء.. الذين أحاطوني بالمحبة والدعم..

وكانوا شركاء في فرح الإنجاز.. كما كانوا سنداً في كل الأوقات..

إخوتي

إلى أصدقائي وزملائي في المشروع.. الذين كان تعاونهم وإخلاصهم سبيل النجاح.. ومشاركتهم مصدر فخر واعتزاز..

أصدقائي في المشروع

إلى أستاذي الفاضل.. الدكتور هاني عماشة.. مشرف المشروع.. الذي أضاء لنا الطريق بعلمه وتوجيهه.. فله مني خالص الشكر والامتنان..

الدكتور هاني عماشة

إلى نفسي التي صبرت وسهرت وتحدّت الصعاب حتى تصل إلى هذه اللحظة.. فكان هذا الإنجاز ثمرة جهدها وإصرارها..

محمد شيخ حسين

إلى من لو قدمت لهما كل الأرض ذهباً.. وكل البحر مداداً.. وكل السماء حريراً..لما وفيت لهما حقّهما..

إليكما..يا من جعلتما منّي من يحلّق في سماء المستحيل.. ويجرؤ على الحلم بما لا يجرؤ الآخرون على حلمه..

أبي وأمي

إلى أخَوَيّ الغاليين.. رفيقا الدرب وسندي في الحياة..
شكراً لكم لأنكم كنتم دائمًا القوة التي تدعمني.. والضحكة التي تزيل همي..

مرهف وملهم

إلى أبطال المشروع.. إلى من جعلوا من كل يوم عمل مغامرة..
ومن كل تحدٍ فرصة للتعلم والنمو. شكراً لكم على كل فكرة..
وعلى كل جهد وكل ابتسامة كانت جزءاً من هذا الإنجاز..

أصدقائي في المشروع

إلى أصدقائي الأعزاء.. إلى من جعلوا من العسِرة أهُون.. ومن الفرح أجمل..

إلى من تركوا بصمتهم في قلبي وذاكرتي.. لكم مني كل الحب والوفاء..

ودعاء لا ينقطع لكم بالسعادة والنجاح..

مجد الدين عبود.. يوسف النجار.. عبادة الحمودة.. وئام السالم
معاذ اليونس.. صبا محمد. مصطفى القاعد. محمد سويداني

اللهم تقبل هذا العمل مني.. واجعله خالصاً لوجهك الكريم..

واجعله ذخراً لي في آخرتي.. ونوراً في قبري.. وسبباً في رضاك عني..

محمد عبدالرحمن

إلى من علماني معنى التضحية والإصرار على النجاح.. إلى من كانا الداعم الأول لي في كل خطوة..
أهدي هذا المشروع لكما بكل حب وامتنان.. فبفضلكما وبفضل تشجيعكما ودعائكما وتضحياتكما الدائمة
استطعت الوصول إلى هذه اللحظة.. إلى من أحمل اسمه بكل فخر والنور الذي أنار دربي..
وإلى من علمتني الأخلاق وصاحبة القلب الحنون وقرّة عيني..

أبي العزيز وأمي الغالية

إلى أخوتي ورفاق دربي وشركاء أحلامي.. إلى من دعموني بلا حدود وأعطوني بلا مقابل..
إلى سندي والكتف الذي لا يميل.. إلى قدوتي وسر نجاحي أنتم الأمان ومصدر قوتي والهامي

أخوتي.. فاطمة.. وليد.. هاجر وزوجها العزيز عثمان.. معتصم.. مؤيد

إلى زملائي وأبطال هذا المشروع.. إلى أصحاب الفكر والهمّة والأخلاق النبيلة..
إلى من يسعون دائماً إلى التميّز والإبداع.. شكراً من القلب لأنه لولا تعاونكم وصبركم وإصراركم على النجاح والوصول لما وصلنا إلى هذه اللحظة.. شكراً لكل ساعة جهد ووقفة صدق قدمتموها.. كانت رحلة مليئة بالتحديات ومن قال أنا لها نالها وأنتم لها..

محمد الشيخ حسين.. سعيد عزّيّة.. محمد عبد الرحمن

إلى أصدقائي وعائلتي الثانية.. إلى من شاركوني الضحكات واللحظات الصعبة.. شكراً إلى نعمة وجودكم في حياتي.. وشكراً إلى دعمكم ومواساتكم الدائم لي..

هبه خالد طيب

الفهرس:

1 الفصل الأول المقدمةIntroduction 1

1.1 مقدمة: 1

2.1 المشكلة المطروحة:..... 1

3.1 الأهداف: 2

4.1 الطريقة العملية المتعبة: 2

5.1 الخطوط العامة للبحث: 2

2 الفصل الثاني الدراسات المرجعية Literature Review..... 7

1.2 مقدمة: 7

2.2 الدراسة الاولى: 8

3.2 الدراسة الثانية:..... 10

4.2 الدراسة الثالثة:..... 11

5.2 الخاتمة:..... 15

3 الفصل الثالث القسم النظري Theoretical Part 19

1.3 مقدمة: 19

2.3 القلب: 19

3.3 وظيفة القلب: 20

4.3 تشريح القلب: 20

1.4.3 البنية الخارجية للقلب:..... 20

2.4.3 الحجرات القلبية: 20

3.4.3 الصمامات القلبية: 21

4.4.3 الأوعية الدموية المرتبطة بالقلب: 21
5.4.3 الجهاز القلبي الناقل Cardiac Conduction System: 22
6.4.3 كهربائية القلب: 23
5.3 مخطط القلب الكهربائي Electrocardiogram – ECG: 24
1.5.3 اتجاهات تخطيط القلب الكهربائي: 24
6.3 طرق الاقتباس بحسب نوع الأقطاب المستخدمة: 26
1.6.3 الأقطاب اللاصقة Wet Electrodes Ag/AgCl: 26
2.6.3 الأقطاب من النوع الجاف Dry Electrodes: 26
3.6.3 الأقطاب النسيجية أو المدمجة في الملابس Electrodes Textile/Smart Fabric: 27
4.6.3 الأقطاب السعوية Capacitive Coupling Electrodes: 28
7.3 طرق الاقتباس بحسب بيئة الاستخدام: 28
1.7.3 أجهزة التخطيط السريرية Clinical ECG Machines: 28
2.7.3 أجهزة المراقبة المحمولة Holter Monitors: 28
3.7.3 الأجهزة القابلة للارتداء Wearable Devices: 29
4.7.3 أنظمة الاقتباس غير التلامسية Non-Contact Systems: 30
8.3 معالجة الإشارة بعد الاقتباس: 30
9.3 الإقفار القلبي Cardiac Ischemia: 30
10.3 تعريف الذكاء الصنعي Artificial Intelligence – AI: 31
1.10.3 تعلم الآلة Machine Learning ML: 31
2.10.3 التعلم العميق Deep Learning DL: 32
4 الفصل الرابع القسم العملي Practical Part 38

1.4 مقدمة: 38
2.4 مخطط العمل: 38
3.4 العتاد المادي: 39
1.3.4 حساس تخطيط القلب AD8232: 39
2.3.4 لوحة التطوير Raspberry Pi 4 Model B: 42
3.3.4 ADS1115 Analog-to-Digital Converter: 46
4.3.4 شاشاتO-LED: 48
5.3.4 برنامج Fritzing: 50
6.3.4 برنامج EasyEda: 51
4.4 الجانب البرمجي: 58
1.4.4 برنامج Visual Studio Code - VS Code: 58
2.4.4 منصة Google Colab: 61
5 الفصل الخامس النتائج والمناقشة Conclusions and Discussion 66
1.5 مقدمة: 66
2.5 النتائج والمناقشة: 66
3.5 المشاكل التي واجهتنا: 66
1.3.5 على الصعيد الطبي: 66
2.3.5 على صعيد العتاد المادي: 67
3.3.5 على صعيد قواعد البيانات: 68
6 الفصل السادس الآفاق المستقبلية Future Work 72
1.6 على الصعيد البرمجي: 72
1.1.6 تطوير خوارزمية التعلم العميق: 72

2.1.6 بناء قواعد بيانات محلية: 72
2.6 من ناحية العتاد المادي: 72
1.2.6 دمج شاشة لمس تفاعلية: 72
2.2.6 توسيع النظام ليشمل حساسات إضافية: 72
3.2.6 تقليل عدد الأقطاب المستخدمة: 73
4.2.6 تحسين جودة الإشارة: 73
5.2.6 تحويل الجهاز إلى نظام مراقبة ذكي مستمر: 73
7 المحلق Supplement 77
1.7 كود كشف قمة الموجة R /R-Peaks Detectors مع كود تقطيع البيانات Beats Slicer: 77
2.7 كود نموذج التعلم العميق: 81
المراجع References 91

فهرس الأشكال:

الشكل(2-1) مثال عن بنية الشبكة CNN1D المستخدمة في تطبيقات السلاسل الزمنية Time Series. [1] 8
الشكل(2-2) بنية الشبكة العصبية CNN-Conv1D.[3] 12
الشكل(2-3) بنية المشفر التلقائي Autoencoder [3].....13
الشكل(3-1) قلب الإنسان. 19
الشكل(3-2) الأجزاء التشريحية الخارجية للقلب.....22
الشكل(3-3) النظام الكهربائي في القلب. 23
الشكل(3-4) مخطط القلب الكهربائي.....24
الشكل(3-5) توضع الأقطاب على جسم المريض أثناء اقتباس إشارة القلب.....25
الشكل(3-6) الأقطاب اللاصقة Wet Electrodes. 26
الشكل(3-7) الأقطاب الجافة.....27
الشكل(3-8) الأقطاب المدمجة في الملابس. 27
الشكل(3-9) الأقطاب السعوية.....28
الشكل(3-10) جهاز Holter. 29
الشكل(3-11) ساعة ذكية. 29
الشكل(3-12) شكل النبضة في مخطط القلب الكهربائي في حالة الإقفار القلبي.....31
الشكل(3-13) الفرق بين التعلم الآلي والتعلم العميق.....32
الشكل(3-14) بنية الشبكة العصبية الاصطناعية. 33
الشكل(3-15) بنية الشبكة العصبية الالتفافية. 34
الشكل(4-1) المخطط الصندوقي للجهاز.....38
الشكل(4-2) حساس تخطيط القلب AD8232.....39
الشكل(4-3) أطراف الحساس AD8232. 40
الشكل(4-4) توضع حساس تخطيط القلب AD8232 على الجسم.....41
الشكل(4-5) لوحة Raspberry Pi 4 Model B. 42
الشكل(4-6) بطاقة تخزين من نوع MicroSD. 43
الشكل(4-7) الموقع الرسمي لتحميل نظام Raspberry Pi.....44
الشكل(4-8) أطراف لوحة Raspberry Pi. 44
الشكل(4-9) رسالة الترحيب عند تشغيل النظام.....45
الشكل(4-10) ربط واجهة المتحكم بالحاسوب.....46

الشكل(4-11) ADS1115. 46
الشكل(4-12) شاشة O-LED. 49
الشكل(4-13) مخطط يوضح مكونات دارة اقتباس الإشارة. (تم تصميمها باستخدام برنامج Fritzing) 49
الشكل(4-14) شعار برنامج Fritzing. 51
تم استخدام برنامج Fritzing في محاكاة الدارة الأولية أثناء تركيبها على لوح الاختبار Breadboard، انظر الشكل(2-1) 51
الشكل(4-16) شعار برنامج EasyEda. 52
الشكل(4-17) مخطط الدارة الكلي، تم تصميمه باستخدام برنامج EasyEDA. 52
الشكل(4-18) توصيل الدارة الكلي، وتصميمها من أجل مرحلة طباعة دارات PCB. 52
الشكل(4-19) مظهر الدارة وترتيب العناصر بشكل ثلاثي الأبعاد. 53
الشكل(4-20) طباعة مسارات PCB Layout على ورق أصفر خاص بالتصوير. 53
الشكل(4-21) الأدوات المستخدمة في نقل الحبر من الورق إلى طبقة النحاس. 54
الشكل(4-23) تحميض الدارة باستخدام مادة كلوريد الحديديك. 55
الشكل(4-24) شكل الدارة من الأسفل بعد انتهاء مدة التحميض. (نلاحظ أن المساحة الصفراء تمثل مادة الفايبر وخطوط الحبر تحتها مسارات الدارة النحاسية). 56
الشكل(4-25) لوح النحاس بعد شحذه (نلاحظ المسارات النحاسية المتبقية من عملية التحميض). 56
الشكل(4-26) الشكل النهائي لدارة الاقتباس يظهر فيها لوحة Raspberry Pi ودارة الاقتباس. 57
الشكل(4-27) قطع علبة ألواح البلكسي. 57
الشكل(4-28) الشكل النهائي للجهاز مع شعار المشروع DL-CIDEA. 58
الشكل(4-29) شعار برنامج VS Code. 59
الشكل(4-30) مخطط صندوقي يوضح آلية عمل خوارزمية Pan-Tompkins. 60
الشكل(4-31) شعار منصة Google Colab. 62

فهرس المصطلحات:

الرمز	اختصار لـ:	المعنى
DL	Deep Learning	التعلم العميق
ECG	Electrocardiogram	مخطط القلب الكهربائي
-	Cardiac Ischemia	الإقفار القلبي
AI	Artificial Intelligence	الذكاء الصنعي
ML	Machine Learning	تعلم الآلة
ADC	Analog to Digital Converter	محول تماثلي – رقمي
ANN	Artificial Neural Networks	الشبكات العصبية الاصطناعية
CNN	Convolutional Neural Network	الشبكات العصبية الالتفافية
CNN-1Conv	One-Dimensional Convolutional Neural Network	الشبكات العصبية الالتفافية أحادية البعد
-	Autoencoder	المشفر التلقائي
-	Time Series	السلاسل الزمنية
PCB	Printed Circuit Boards	لوح الدائرة المطبوعة

الملخص

يتناول هذا البحث تصممي وتنفيذ جهاز طبي متكامل يحمل اسم DL-CIDEA، يتألف النظام من جانب عتادي يضم مستشعر AD8232 ECG ولوحة Raspberry Pi 4B، وهما مسؤولان عن اقتباس إشارة القلب الكهربائي ومعالجتها الأولية، أما الجانب البرمجي وهو جوهر النظام فهو نموذج تعلم عميق مُدرب مسبقاً مبني على شبكة عصبية التفافية أحادية البعد CNN1D، والذي يتلقى الإشارات المعالجة ويصنفها بدقة ضمن ثلاث فئات: نبضة إقفارية، نبضة طبيعية، ونبضة غير طبيعية لم يتم تشخيصها.

يتمتع الجهاز بآلية التحليل الفوري والتي تعطي النظام ميزة كبيرة مقارنةً بالطرق التشخيصية التقليدية، مما يعزز سرعة ودقة الكشف عن حالات الإقفار القلبية، وتظهر النتائج جدوى وفعالية استخدام نهج التعلم العميق المتكامل لإنشاء أداة تشخيصية موثوقة يمكنها دعم المتخصصين في المجال الطبي وتحسين كفاءة الرعاية القلبية الوعائية.

Abstract

This research deals with the design and implementation of an integrated medical device called **DL-CIDEA**. The system consists of a hardware side that includes an AD8232 ECG sensor and a Raspberry Pi 4B board, which are responsible for capturing the electrocardiogram signal and its initial processing. The software side, which is the core of the system, is a pre-trained deep learning model based on a one-dimensional convolutional neural network (CNN1D), which receives the processed signals and accurately classifies them into three categories: ischemic pulse, normal pulse, and undiagnosed abnormal pulse.

The device's instant analysis mechanism offers a significant advantage over traditional diagnostic methods, enhancing the speed and accuracy of cardiac ischemia detection. The results demonstrate the feasibility and effectiveness of using an integrated deep learning approach to create a reliable diagnostic tool that can support medical professionals and improve the efficiency of cardiovascular care.

الفصل الأول

المقدمة

Introduction

1 الفصل الأول

المقدمة

Introduction

1.1 مقدمة:

تُعَدُّ الأمراض القلبية من أبرز التحديات الصحية التي تواجه العالم المعاصر، إذ تحتل المراتب الأولى بين أسباب الوفاة عالمياً، يُعتبر تخطيط القلب الكهربائي Electrocardiogram ECG الأداة الأكثر استخداماً للكشف عن مختلف الاضطرابات القلبية، نظراً لكونه وسيلة غير جراحية وسريعة توفر معلومات دقيقة حول النشاط القلب الكهربائي، ورغم هذه الأهمية فإن الاعتماد على التفسير البشري لتخطيط القلب يتطلب مستوى عالي من الخبرة والممارسة، حيث قد يختلف التشخيص من طبيب لآخر تبعاً لعوامل الخبرة والتدريب، مما يفتح الباب أمام احتمالية وقوع أخطاء أو تأخر في اكتشاف الحالات الحرجة، هذه التحديات تبرز الحاجة إلى حلول تقنية قادرة على رفع مستوى الدقة والموثوقية في عملية التشخيص.

خلال السنوات الأخيرة، شهد المجتمع العلمي تقدماً ملحوظاً في توظيف الذكاء الاصطناعي وتقنيات التعلم العميق في المجال الطبي، فقد تناولت دراسات عديدة إمكانية استخدام الشبكات العصبية الاصطناعية Artificial Neural Network ANN في تحليل إشارات القلب الكهربائية والتعرف على الأنماط المرضية بدقة عالية حيث أظهرت نتائج واعدة في تقليل الاعتماد الكامل على التفسير البشري وتعزيز سرعة وكفاءة التشخيص.

2.1 المشكلة المطروحة:

تم اختيار تصميم وتنفيذ الجهاز نظراً للنسب المتفاوتة بين الكفاءة والزمن اللازم لتشخيص الأمراض بين الطبيب البشري والذكاء الاصطناعي، حيث أن الزمن اللازم الذي يستغرقه الطبيب أثناء عملية التشخيص أطول والدقة أقل بسبب الأخطاء البشرية والعشوائية التي تحدث، مما دفعنا لتصميم جهاز ذو زمن تشخيص أقل وكفاءة أعلى، وعلى الرغم أن الزمن الذي يوفره الجهاز لا يتجاوز بضعة دقائق، إلا أن هذه الدقائق القليلة هي الفارقة في حالات المرضى الحرجة.

3.1 الأهداف:

يهدف هذا المشروع إلى تصميم جهاز طبي متكامل لتشخيص الأمراض القلبية دون الحاجة لتدخل الطبيب حيث يقوم نموذج التعلم العميق المدرب مسبقاً بعملية التشخيص، حيث يتكامل الجانب العتادي والجانب البرمجي معاً لتشكيل الجهاز، بحيث يقوم الجهاز بوظيفة كل من جهاز تخطيط القلب الكهربائي وتشخيص الطبيب.

4.1 الطريقة العملية المتعبة:

تم تصميم دارة اقتباس الإشارة من خلال برنامج EasyEda حيث تتألف من حساسين لإشارة القلب من النوع Ad8232 ومحول رقمي تماثلي ADS1115 لتحويل إشارة القلب الكهربائية التماثلية Analog إلى قيم رقمية Digital ليتم معالجتها أولياً ضمن لوحة التطوير Raspberry Pi 4، يتم تغذية الدارة من خلال بطاية ليثيوم 3.7V من نوع 18650، أما بالنسبة للجانب البرمجي فهو يتألف من: كود المعالجة الأولية للبيانات والذي يتم على عدة مراحل، حيث يتم أولاً كشف قمة الموجة R من خلال R Wave Peaks Detector ثم بعدها يتم تقطيع Slicing التسجيل القلبي إلى نبضات قلبية اعتماداً على موقع قمة الموجة R وعلى طول مرجعي ثابت واعتماداً على تردد العينات Frequency Sampling FS. أما بالنسبة للكود الثاني فهو نموذج التعلم العميق Deep Learning Model الذي تم تدريبه على قواعد بيانات St. Petersburg Institute of Cardiological Technics 12-lead Arrhythmia Database و European ST-T Database1.0.0 والذي يقوم بمهمة تشخيص النبضات Beats Classification. تقوم دارة الـ Raspberry Pi بوظيفة الـ "جسر" بين الجانب المادي والجانب البرمجي، حيث يتم تحميل نموذج التعلم العميق على بيئة Raspberry Pi ويكون خرج المعالجة الأولية للنبضات بعد عملية الاقتباس هو دخل الشبكة العصبية، وبعد أن يحدد النموذج تنصيف النبضات يتم عرض الحالة على شاشة O-LED 0.96inch.

5.1 الخطوط العامة للبحث:

تنقسم هذه الأطروحة إلى أربعة فصول رئيسية، حيث يتناول الفصل الأول التعريف العام بالمشروع، مع عرض أهدافه والمراحل الأساسية التي مر بها. أما الفصل الثاني فيُخصص لمراجعة الأدبيات والدراسات السابقة ذات الصلة، والتي تشكل الخلفية العلمية للعمل. ويُركّز الفصل الثالث على الجانب النظري، حيث يشمل عرضاً لتشريح القلب ووظيفته الفيزيولوجية، بالإضافة إلى مبدأ تخطيط القلب الكهربائي والتغيرات

المرتبطة ببعض الأمراض القلبية المستهدفة مثل الإقفار القلبي، كما يتناول مفهوم الاقتباس الكهربائي للقلب والتعريف بأساسيات الذكاء الاصطناعي والتعلم العميق، أما الفصل الرابع فيمثل الجانب العملي والتطبيقي، إذ يتضمن تصميم دارة الاقتباس وآلية معالجة الإشارة، إلى جانب تجهيز البيانات وبناء نموذج التعلم العميق وتدريبه واختباره وصولاً إلى ربطه مع الدارة. ويختتم هذا الفصل بعرض النتائج العملية التي تم الحصول عليها، مع مناقشتها علمياً واستخلاص الاستنتاجات أما الفصل الخامس يتضمن طرح التوصيات والآفاق المستقبلية.

الفصل الثاني

الدراسات المرجعية

Literature Review

2 الفصل الثاني

الدراسات المرجعية

Literature Review

1.2 مقدمة:

شهد مجال تشخيص أمراض القلب باستخدام تخطيط القلب الكهربائي تطوراً ملحوظاً خلال العقد الأخير، حيث نُشرت العديد من الدراسات والأبحاث العلمية التي تناولت هذا الموضوع من زوايا مختلفة. وقد سعى الباحثون في هذا المجال إلى الاستفادة من تقنيات الذكاء الصنعي والتعلم العميق من أجل تحسين دقة التشخيص وتسريع عملية تحليل الإشارات القلبية، وذلك لتجاوز حدود الطرق التقليدية المُعْتَمِدة على الخبرة البشرية وعلى استخلاص الميزات وكشف الأنماط بشكل يدوي.

يهدف هذا الفصل إلى استعراض بعض الدراسات المرجعية المهمة التي تناولت تصنيف الإشارات القلبية الكهربائية باستخدام خوارزميات الذكاء الاصطناعي، مع التركيز على منهجية العمل التي اتبعها الباحثون في كل دراسة، إضافةً إلى النتائج التي توصّلوا إليها، ويساعد هذا العرض في تكوين صورة شاملة عن الجهود البحثية السابقة، كما يبرز موقع هذا المشروع ضمن السياق العلمي القائم.

2.2 الدراسة الاولى:

Deep Learning for ECG Classification

استخدام التعلم العميق في تصنيف مخطط القلب الكهربائي [1].

هدفت هذه الدراسة إلى تطوير نموذج يعتمد على التعلم العميق لتصنيف إشارات تخطيط القلب الكهربائي بشكل آلي، وذلك لتجاوز محدودات الطرق التقليدية التي تعتمد على استخلاص ميزات يدوياً والتي قد تفشل في تمثيل الأنماط المعقدة في البيانات الطبية، حيث اعتمد الباحثون على إشارات قلب من تسجيلات قصيرة لقناة واحدة Single Lead، مقسمة إلى أربع فئات: النظم الجيبي الطبيعيNormal Sinus Rhythm، اضطرابات النظم القلبية Arrhythmic، وأنماط أخرى Other rhythms، إشارات مشوّشة Noisy Signals. البيانات كانت غير متوازنة (60% منها طبيعية)، وللتغلب على ذلك استخدم الباحثون تقنيات زيادة البيانات Data Augmentation مثل إزاحة القيم الزمنية وتكرار المقاطع لتوحيد الطول. تمت المعالجة الأولية للبيانات من خلال طرح القيمة الوسطية من السلاسل الزمنية وتقسيمها على الانحراف المعياري لتطبيع الإشارات. تم بناء نموذج التعلم العميق والذي يتألف من شبكة عصبية التفافية أحادية البعد Convolution Neural Network 1 Dimension CNN1Dمكونة من 7 طبقات التفافية (Convolutional Layers) بعرض مرشح 5x5 و128 عصبوناً، وطبقات Max-Pooling وDropout بعد كل طبقة، وطبقة GlovalAveragePooling، 3 طبقات Fully Connected Network FCN بعدد خلايا عصبية (256/128/64)، وطبقة Dropout بعد كل طبقة، وطبقة الخرج كانت بتابع تفعيل Softmax لأربع فئات.

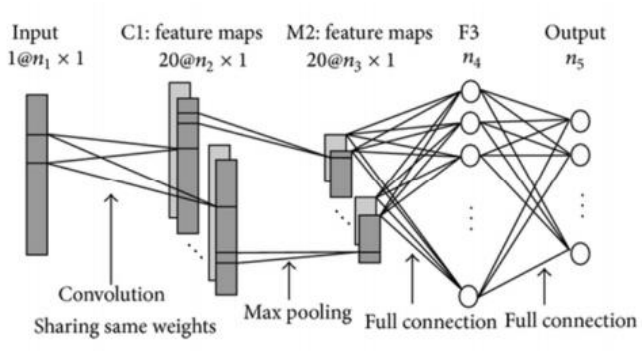

الشكل(1−2) مثال عن بنية الشبكة CNN1D المستخدمة في تطبيقات السلاسل الزمنية Time Series. [1]

حقّق النموذج دقّة تصنيف وصلت إلى حوالي 86% على بيانات التحقق Data Validation، وأظهرت النتائج أن الشبكات العصبية الالتفافية قادرة على استخراج الميزات تلقائياً من الإشارات القلبية دون الحاجة إلى خبرة طبية سابقة في هندسة الميزات Features Engineering.

ومع ذلك أشار الباحثون إلى أن النموذج ما زال يعاني من تحديات مثل التعقيد الحسابي، وعدم وضوح أفضل بنية يمكن اعتمادها بشكل عام (عدد الطبقات، نوع خوارزمية التحسين وغيرها)، أوصت الدراسة بإمكانية تحسين النتائج مستقبلاً عبر إجراءات معالجة مسبقة أكثر تقدماً أو استخدام شبكات توليدية Generative Adversarial Networks GANs لتوازن البيانات.

تبرز أهمية هذه الدراسة كونها أوضحت جدوى استخدام شبكات CNN أحادية البعد في تصنيف إشارات ECG، وأثبتت قدرتها على تجاوز أساليب التعلم الآلي التقليدية، إلا أن العمل اقتصر على البيانات المسجّلة مسبقاً ولم يشمل تطوير دارة اقتباس فعلية للإشارة من المريض. وهنا يأتي تميز مشروعنا الذي يجمع بين دارة الاقتباس العتادية ونموذج التعلم العميق لتحقيق نظام عملي متكامل يمكن تطبيقه في الواقع السريري.

3.2 الدراسة الثانية:

Detection of myocardial ischemia by intracoronary ECG using convolutional neural networks

الكشف عن إقفار العضلة القلبية بواسطة تخطيط القلب الكهربائي داخل الشريان التاجي باستخدام الشبكات العصبية التلافيفية [2].

هدفت هذه الدراسة إلى تطوير نموذج يعتمد على التعلم العميق باستخدام الشبكة CNN مصمّمة مسبقاً لاكتشاف الإقفار القلبي Myocardial Ischemia باستخدام تخطيط القلب داخل الشريان التاجي Intracoronary ECG icECG، عبر استخدام نهج توليد الفرضيات hypothesis-generating approach بدلاً من الاعتماد التقليدي على قياسات يدوية مثل انزياح مقطع ST. تم جمع بيانات لـ 228 مريضاً ممن يعانون من متلازمة الشريان التاجي المزمن Chronic Coronary Syndrome، والذين خضعوا لتجارب سريرية تضمنت انسداد صناعي لمجرى الشريان التاجي لمدة دقيقة، ما أنتج 893 تسجيل icECG للمرحلتين غير إقفاري (قبل الانسداد) وإقفاري (نهاية الانسداد)، تم استخدام نماذج CNN مسبقة التدريب مثل GoogLeNet وResNet101، وأُعيد تدريبها باستخدام تقنية نقل التعلم Transfer Learning لتعلم التمييز بين الحالات الإقفارية وغير الإقفارية. حقّق أفضل نموذج أداءً بدقة تصنيف عالية، حيث أظهر حساسية Sensitivity بنسبة 93% ونوعية Specificity بنسبة 92%، وبلغت المساحة تحت المنحني Area Under Curve AUC لمنحني Receiver Operating Characteristics ROC قيمة تساوي 0.903 ± 0.043. ومن خلال تحليل خرائط التنشيط Activation Patterns وُجد أن النموذج يركّز على مقطع ST وموجة T، مما يتوافق مع المعايير الفيزيولوجية للكشف عن الإقفار.

4.2 الدراسة الثالثة:

Deep Learning Based Myocardial Ischemia Detection in ECG Signals

الكشف عن إقفار العضلة القلبية في إشارات تخطيط القلب الكهربائي باستخدام التعلم العميق [3].

تهدف الدراسة إلى تطوير واختبار نماذج تعلم عميق للكشف التلقائي عن إقفار العضلة القلبية باستخدام إشارات ECG، لتسريع ودعم عملية التشخيص الطبي، حيث أكدت الدراسة على أن مخطط القلب الكهربائي أداة أساسية لمراقبة وتشخيص الأمراض القلبية خصوصاً وأن الإقفار يعد من أهم أسباب الوفاة عالمياً حيث يؤدي إلى ضعف ضخ القلب. اعتمد الباحثون في عملهم على قاعدة البيانات الأوروبية European ST-T Database، حيث تحتوي على 90 تسجيل تم اقتباسهم من 79 مريضاً، حيث تألفت مجموعة المرضى من 70 رجلاً أعمارهم بين 30 و84، و8 نساء أعمارهم بين 55 و71، حيث تم تشخيص الإقفار القلبي أو تم الاشتباه بذلك لكل شخص من المجموعة السابقة، يبلغ طول تسجيل ECG في قاعدة البيانات الأوروبية حوالي 1.8 مليون عينة Sample أي بطول تسجيل ساعتين وبتردد عينات Fs يساوي 250Hz، تم استخدام مكتبة BioSppy لاستخراج النبضات القلبية من خلال كشف قمة الموجة R، وتم الحصول على 500,000 نبضة سليمة و800 نبضة مريضة. تمت تجربة ثلاث نماذج لاستحصال النتائج حيث اعتمد النموذج الأول على بنية الشبكة العصبية الالتفافية أحادية البعد CNN-Conv1D حيث تقوم الشبكة بمهمة التصنيف الثنائي Binary Classification حيث تصنف النبضات إلى نبضات (سليمة/مريضة) وتم تدريبها على بيانات متوازنة من حيث عدد التصنيفات (800 نبضة سليمة + 800 نبضة مريضة).

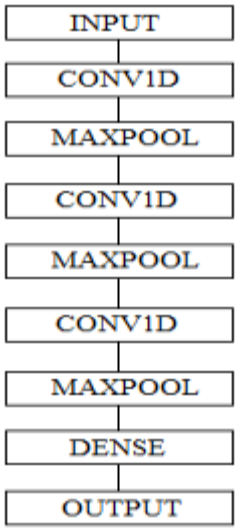

الشكل(2-2) بنية الشبكة العصبية CNN-Conv1D.[3]

أما بالنسبة للنموذج الثاني فتم استخدام المشفر التلقائي Autoencoder للكشف عن الحالات الشاذة Outlier Detection، تم تدريب هذ النموذج على مجموعة النبضات السليمة فقط (500,000 نبضة) وبناءً على أداء إعادة التشكيل Reconstruction Performance[1] فإن النبضات المريضة ستظهر بمعدل خطأ أعلى لأداء إعادة التشكيل، حيث أن معدل خطأ إعادة التشكيل هو متوسط مربع الفروقات بين إشارة الدخل وإشارة الخرج، تتكون بنية المشفر التلقائي – والذي يعتمد فقط على طبقات من نوع Dense Layer – من 7 طبقات، تمتاز طبقة الدخل D1 وطبقة الخرج D7 بأن لها نفس البعد والذي يساوي 200 عصبون Neurons، وعلى غرار الشبكات العصبية العادية فإن بنية المشفر التلقائي تتألف من طبقة إدخال، طبقات تمثل المشفر Encoder، طبقات تمثل مفكك التشفير Decoder، طبقة الخرج، إن الطبقات من D2 حتى D4 تمثل المشفر وأبعادها تقابل الأطوال 32 و 16 و 8، أما الطبقات من D4 حتى D7 فتمثل مفكك التشفير وأبعادها تقابل الأطوال 8 و 16و 32، وبالتالي يمكن الملاحظة بأن الطبقة D4 هي ذات الطبقة الأقصر، اعتمدت الدراسة على تابع التنشيط Rectified Linear Unit ReLU، وبالطبع تم استخدام تابع التفعيل Softmax كي تابع تفعيل في طبقة الخرج.

[1] Reconstruction Performance أو أداء إعادة التشكيل: هو مقياس قدرة النماذج من نمط المشفرات التلقائية Autoencoders على إعادة بناء الإشارات الأصلية التي تدرب عليها النموذج، حيث على غرار الشبكات العصبية الالتفافية فهو لا يعتمد على التصنيف مباشرة وإنما يعتمد على خطأ إعادة التشكيل كمعيار.

الشكل(3-2) بنية المشفر التلقائي Autoencoder [3].

وبالنسبة للنموذج الثالث فكان نموذجاً هجيناً Hybrid Model بين الشبكة العصبية الالتفافية أحادية البعد وبين المشفر التلقائي. تم اختبار النماذج الثلاث كما تم توضيحه سابقاً وكانت النتائج كما هي موضحة في الجدول :

Model	Accuracy	Sensitivity	Specificity	Precision	F1 Score
Conv1D	85.71%	89.1%	82.7%	81.7%	0.852
Autoencoder	75.00%	60.2%	87.8%	81%	0.691
Hybrid	88.6%	95.5%	82.7%	82.7%	0.886

تأتي أهمية هذه الدراسة في إيصال قوة وكفاءة النماذج الهجينة المستخدمة في تطبيقات التصنيف Classification، كما وتشير إلى التحسن الكبير في أداء نموذج الشبكة العصبية الالتفافية أحادية البعد بعد دمجها بالمشفر التلقائي.

العنصر	الدراسة الثالثة	الدراسة الثانية	الدراسة الأولى
الهدف	الكشف عن إقفار العضلة القلبية باستخدام إشارات ECG السطحية.	اكتشاف الإقفار القلبي عبر تخطيط القلب داخل الشريان التاجي icECG .	تصنيف إشارات ECG متعددة الفئات (طبيعية، اضطرابات، أنماط أخرى، مشوشة).
قاعدة البيانات	قاعدة البيانات الأوروبية ST-T 90 تسجيل من 79 مريضاً، كل تسجيل بطول ساعتين وتردد 250 هرتز	بيانات سريرية لـ 228 مريضاً أعطت 893 تخطيطاً من icECG	تسجيلات قصيرة لقناة واحدة (Single Lead)، بيانات غير متوازنة.
عدد العينات	(500,000 نبضة سليمة + 800 نبضة مريضة) بعد التقطيع	893 تسجيل (مرحلتين: غير إقفاري/إقفاري).	(لم يُذكر بشكل صريح) لكن تم تقسيم المقاطع وتوحيد الطول عبر (Data Augmentation)
المعالجة الأولية	تم استخدام مكتبة BioSppy لاستخراج النبضات	لا تعتمد على استخراج يدوي للميزات. تم الاعتماد على raw signalsمع نقل التعلم.	-تطبيع الإشارات (طرح القيمة الوسطية / القسمة على الانحراف المعياري) - . Data Augmentation (إزاحة زمنية، تكرار)
النماذج المستخدمة	ثلاث نماذج: CNN – Autoencoder – Hybrid	CNN مسبقة التدريب (GoogLeNet, ResNet101) مع Transfer Learning.	7 CNN1D طبقات التفاف + MaxPooling + Dropout + FCN
عدد الطبقات	Autoencoder: 7 طبقات Dense (200→32→16→8→16→32→200).	عمق الشبكة يعتمد على النموذج (ResNet101 أعمق من GoogLeNet).	7طبقات Convolution + 3 Fully Connected.
أداء النماذج	Conv1D: 85.7% Autoencoder: 75% Hybrid: 88.6%	Sensitivity: 93% Specificity: 92% AUC : 0.90.	Accuracy: 86%.
المزايا	أظهر قوة النماذج الهجينة - .دراسة شاملة بتجارب متعددة.	نموذج دقيق وسريري - .توافق النتائج مع الفيزيولوجيا (ST, T).	-استخراج تلقائي للميزات دون خبرة بشرية - .إثبات جدوى CNN1D في ECG.
القيود	البيانات محدودة (800 نبضة مريضة فقط)النموذج يحتاج تحسين لتوسيع قاعدة التدريب.	(بيانات خاصة) داخل الشريان صعوبة التعميم على ECG السطحي.	بيانات غير متوازنة، تعقيد حسابي عالٍ.

5.2 الخاتمة:

بعد الاطلاع على الدراسات سيتم اعتماد قاعدة البيانات الأوروبية في هذا البحث، كما سيتم العمل على استخدام الشبكة العصبية الالتفافية أحادية البعد.

الفصل الثالث

القسم النظري

Theoretical Part

3 الفصل الثالث

القسم النظري

Theoretical Part

1.3 مقدمة:

يقدم هذ الفصل شرحاً موسعاً عن القلب، حيث يشمل التعريف بمكوناته الرئيسية، ويسهب في شرح المنظومة الكهربائية القلبية من حيث أجزائها وآلية عملها التي تعد أساس النبض، كم يعرض بشكل تفصيلي آلية اقتباس الإشارة الكهربائية القلبية وطرقها، ويختتم الفصل بالتوسع في مخطط القلب الكهربائي وقراءته ودوره في توجيه التشخيص.

2.3 القلب:

عضلة مخططة لا إرادية تقع في منتصف الصدر وتميل قمته نحو اليسار قليلاً، يكون محمياً بعظام القفص الصدري من الأمام، وبالعمود الفقري من الخلف، تحتضنه الرئتان من الجانبين، ويرتكز على الحجاب الحاجز من الأسفل.

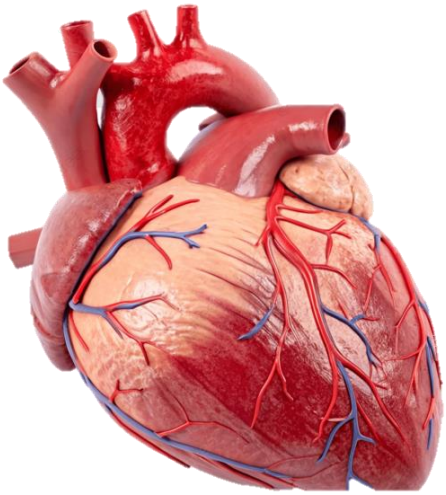

الشكل(1-3) قلب الإنسان.

3.3 وظيفة القلب:

تتمثل الوظيفة الأساسية للقلب في ضخ الدم إلى جميع أجزاء الجسم لضمان إيصال الأكسجين والمواد الغذائية إلى الخلايا والتخلص من ثاني أكسيد الكربون والفضلات، ويمكن تبسيط هذه الوظائف في أربعة محاور رئيسية، إذ يقوم القلب أولاً بضخ الدم المؤكسج (أي الغني بالأكسجين) حيث يستقبل الدم من الرئتين عبر الأوردة الرئوية ثم يقوم البطين الأيسر بضخ الدم عبر الشريان الأورطي (الأبهر) إلى جميع أنحاء الجسم، أما ثانياً فيضخ القلب الدم غير المؤكسج (الفقير بالأكسجين) من خلال استقباله الدم العائد من الجسم عبر الوريدين الأجوفين العلوي والسفلي، ليعمل البطين الأيمن على دفعه عبر الشريان الرئوي باتجاه الرئتين حيث يحدث تبادل الغازات، وثالثاً يسهم القلب في الحفاظ على ضغط الدم والدورة الدموية، إذ يعمل كمضخة عضلية تحافظ على جريان الدم بشكل مستمر، وأخيراً يقوم القلب بتنظيم إيقاع ضرباته بفضل العقدة الجيبية الأذينية Sinoatrial Node - SA Node والعقدة الأذينية البطينية Atrioventricular Node – AV Node حيث تنتج هذه البُنى نبضات كهربائية ذاتية تحافظ على انتظام النشاط القلبي.

4.3 تشريح القلب:

1.4.3 البنية الخارجية للقلب:

يتكون القلب من عدة بنى أساسية تساهم في حمايته وأداء وظائفه الحيوية، إذ يُعد الغشاء الخارجي المعروف بالتامور غلافاً يحيط بالقلب ويحميه ويثبّته داخل الصدر، أما جدران القلب فهي تتألف من ثلاث طبقات متميزة، تبدأ بالشغاف Endocardium الذي يمثل طبقة رقيقة تبطن الحجرات من الداخل، تليه عضلة القلب Myocardium وهي الطبقة العضلية السميكة المسؤولة عن عملية الانقباض، ثم النخاب Epicardium الذي يشكل الطبقة الخارجية المغطية للقلب ويُعد جزءًا من التامور.

2.4.3 الحجرات القلبية:

القلب مقسم إلى أربع حجرات تعمل بتكامل للحفاظ على الدورة الدموية هما الأذينتين والبطينين، إذ يستقبل الأذين الأيمن الدم غير المؤكسج العائد من مختلف أجزاء الجسم، لينتقل بعدها إلى البطين الأيمن الذي يقوم بضخه باتجاه الرئتين من خلال الشريان الرئوي من أجل تبادل الغازات، وفي المقابل، يستقبل الأذين الأيسر الدم المؤكسج القادم من الرئتين عن طريق الأوردة الرؤية الأربعة، ثم يقوم البطين الأيسر بضخ الدم عبر الشريان الأبهر إلى جميع أجزاء الجسم، مما يضمن إمداد الأنسجة بالأكسجين والمواد الغذائية

اللازمة. يُطلق على الأذين والبطين الأيمنين اسم القلب الأيمن، بينما يشكل الأذين والبطين الأيسرَين القلب الأيسر.

3.4.3 الصمامات القلبية:

تُعد الصمامات القلبية أجزاءً أساسية في تنظيم اتجاه تدفق الدم ومنع رجوعه، ولها أنواع عدة حيث يوجد الصمام ثلاثي الشرف بين الأذين الأيمن والبطين الأيمن، والصمام الرئوي بين البطين الأيمن والشريان الرئوي، بينما يقع الصمام التاجي أو الميترالي بين الأذين الأيسر والبطين الأيسر، إضافةً إلى الصمام الأبهري الذي يفصل البطين الأيسر عن الشريان الأبهر. ومع التقدم في العمر أو نتيجةً للإصابة ببعض الأمراض، قد تتعرض هذه الصمامات إلى التليف أو تفقد كفاءتها الوظيفية، الأمر الذي يؤدي إلى حالات من التضيق أو الارتجاع، وهو ما قد يستدعي التدخل الطبي من خلال الإصلاح أو الاستبدال سواء جراحياً أو عبر القثطرة.

4.4.3 الأوعية الدموية المرتبطة بالقلب:

تُعد الأوعية الدموية المرتبطة بالقلب عنصراً أساسياً في ضمان استمرارية عمله ووظائفه الحيوية، إذ تقوم الشرايين التاجية Coronary Arteries بتغذية العضلة القلبية بالدم الغني بالأكسجين. تتفرع الأوعية الدموية المرتبطة بالقلب حتى تغذي جميع خلايا العضلة القلبية، حيث يتفرع الشريان التاجي إلى عدة شرايين كل منها يغذي منطقة من النسيج القلبي؛ فهناك الشريان التاجي الأيسر LCA والشريان الأمامي النازل LAD المسؤولات عن تغذية الجدار الأمامي للبطين الأيسر والحاجز بين البطينين، ويقوم الشريان المنعطف LCX بتغذية الجدار الجانبي والخلفي للبطين الأيسر، أما الشريان التاجي الأيمن RCA فيغذي البطين الأيمن والعقدة الجيبية الأذينية وجزءاً من البطين الأيسر، ويتفرع منه الشريان النازل الخلفي PDA. وتجدر الإشارة إلى أن السيادة التاجية تختلف بين الأفراد، حيث تكون في 70% من الحالات سيادة يمنى، وفي 20% سيادة يسرى، بينما تكون مشتركة في نحو 10% من الأشخاص. وبالإضافة إلى ذلك، تقوم الأوردة التاجية بتصريف الدم من عضلة القلب إلى الجيب التاجي، في حين يضخ الشريان الأبهر الدم من البطين الأيسر لتغذية مختلف أجزاء الجسم، ويعمل الشريان الرئوي على نقل الدم من البطين الأيمن إلى الرئتين، بينما تعود الأوردة الرئوية بالدم المؤكسج إلى الأذين الأيسر، في حين تنقل أوردة الأجوف الدم غير المؤكسج إلى الأذين الأيمن.

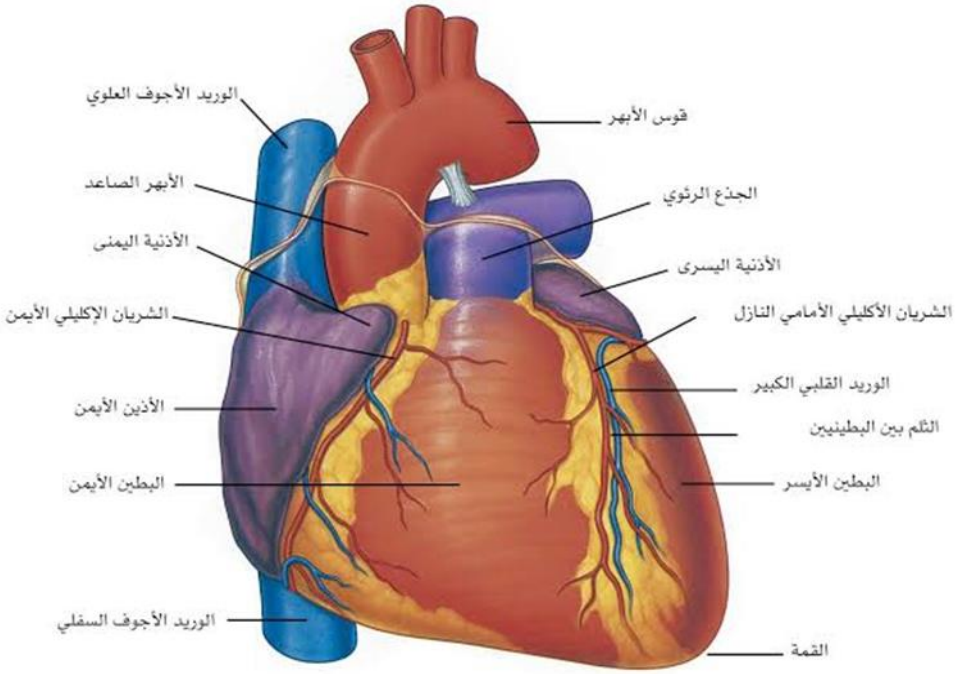

الشكل(2-3) الأجزاء التشريحية الخارجية للقلب.

5.4.3 الجهاز القلبي الناقل Cardiac Conduction System:

يُعد النظام الكهربائي في القلب أساس عملية توليد وتنظيم النبضات، حيث تبدأ هذه العملية من العقدة الجيبية الأذينية التي تعمل كناظمة خطى Pacemaker وصاحبة النظم الأسرع في القلب، تنطلق منها موجة التنبيه القلبي عبر نزع استقطاب الأذينات، إذ تقع هذه العقدة عند مصب الوريد الأجوف العلوي في الأذينة اليمنى، ومنها ينتشر التنبيه إلى الأذينات، وتبدأ موجة نزع الاستقطاب في الأذينة اليمنى أولاً ثم تنتقل إلى الأذينة اليسرى عبر السبل بين العقدية والسبل بين الأذينية، والتي تضم ثلاثة سبل رئيسية من أبرزها حزمة باكمان Bachmann's Bundle التي تؤمن وصول التنبيه إلى الأذينة اليسرى، وبعد اكتمال انتشار التنبيه ضمن الأذينات ينتقل إلى العقدة الأذينية البطينية الواقعة عند الوصل الأذيني البطيني في الجدار الخلفي للأذينة اليمنى، وتتمثل وظيفة هذه العقدة في إحداث تأخير بسيط في نقل التنبيه إلى البطينات، مما يسمح للأذينات بإنهاء انقباضها قبل بدء انقباض البطينات، ومن هناك ينتقل التنبيه عبر حزمة هيس التي تنقسم إلى غصنين رئيسيين: غصن أيسر يتميز بثخانته وسرعة نقله العالية ويمر في الحاجز بين البطينين ليتفرع بدوره إلى فرعين رئيسيين هما الأمامي العلوي والخلفي السفلي بالإضافة إلى فرع صغير يغذي الحاجز بين البطينين، أما الغصن الأيمن فيكون أرفع وأقل سرعة ويمر تحت الشغاف في البطين

الأيمن. بعد ذلك يصل التنبيه إلى ألياف بوركنجي التي تقوم بتوزيعه بسرعة إلى جميع أقسام البطين، وتبدأ عملية نزع استقطاب البطينات من الحاجز بين البطينين من اليسار إلى اليمين نتيجة كون الغصن الأيسر أسرع من الأيمن، ثم تنتشر الموجة الكهربائية إلى كافة أجزاء البطينين مع أرجحية واضحة للبطين الأيسر بسبب كتلته العضلية الأكبر وسماكة غصنه الأيسر.

6.4.3 كهربائية القلب:

يمتلك قلب الإنسان نظاماً مميزاً للتنبيه والتقلص الذاتي، حيث ينبض ما يقارب مئة ألف مرة في اليوم الواحد، وما يقارب ثلاث مليارات مرة في متوسط حياة الفرد. يتم هذا النشاط بوساطة نظام متخصص يعمل على توليد الدفعات الكهربائية المتزامنة ونقلها إلى جميع أنحاء القلب، إضافة إلى مكونات أخرى لكل منها دورها الخاص

عند دراسة العضلة القلبية نسيجياً يمكن أن نميز نوعين أساسيين من الخلايا وهي الخلايا العضلية وهي المسؤولة عن الوظيفة الانقباضية للقلب حيث تتميز بسرعة نقل منخفضة، والخلايا الناقلة والتي تكون مسؤولة عن توليد ونقل الإشارات الكهربائية في العقد القلبية، وتقوم بدور التنظيم الكهربائي لتقلص العضلة القلبية، وتمتاز بسرعة نقل عالية.

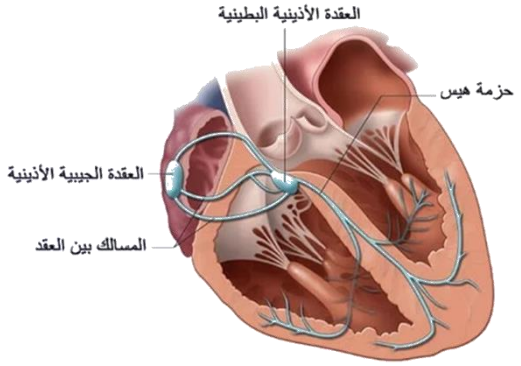

الشكل(3-3) النظام الكهربائي في القلب.

5.3 مخطط القلب الكهربائي Electrocardiogram – ECG:

يُعد تخطيط القلب الكهربائي وسيلة أساسية لتقييم حالة القلب، حيث يزوّد الطبيب بمعلومات دقيقة حول نظم القلب وسرعته، وثخانة أو ضخامة حجراته، بالإضافة إلى اضطرابات النظم القلبية ومصدرها، وكذلك أذيات القلب سواء كانت خلقية أو ناجمة عن الإقفار أو تأثير بعض الأدوية، ويعتمد تحليل تخطيط القلب على الموجات والمركبات الكهربائية الأساسية، فالموجة P تعكس نزع استقطاب الأذينتين، في حين تشير القطعة PR إلى التأخير الذي يحدث في العقدة الأذينية البطينية أما المركب QRS فيمثل نزع استقطاب البطينين، بينما تعكس الموجة T عملية عودة استقطاب البطينين، في حين تنتج الموجة U عن عودة الاستقطاب المتأخر لألياف بوركنجي.

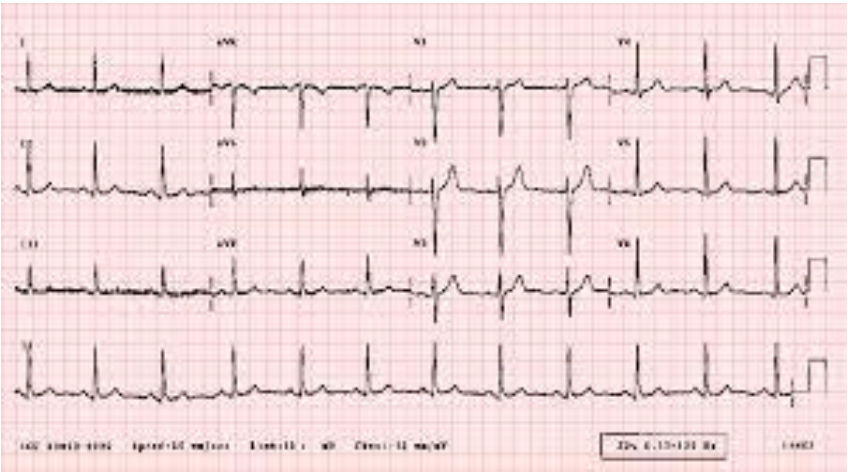

الشكل(4–3) مخطط القلب الكهربائي.

1.5.3 اتجاهات تخطيط القلب الكهربائي:

يوجد 12 اتجاهاً رئيسياً في تخطيط القلب، وكل منها يمثل رؤية مختلفة لجدار القلب على المستويين الجبهي والأفقي، مما يوفر صورة ثلاثية الأبعاد للقلب، حيث تقسم الاتجاهات إلى اتجاهات طرفية Limb Leads، حيث تنقسم الاتجاهات الطرفية إلى نوعين رئيسيين، الأول هو الأقطاب ثنائية القطب Standard Bipolar Leads ويشمل الاتجاهات I وII وIII، والثاني هو الأقطاب أحادية القطب Augmented Unipolar Leads ويضم الاتجاهات aVR aVL aVF، وتشكل هذه الاتجاهات الثلاثة القياسية معاً ما يُعرف بمثلث آينتهوفن Einthoven’s Triangle الذي يحيط بالقلب، مما يتيح تسجيل النشاط الكهربائي للقلب من زوايا مختلفة لتقييم وظيفته بدقة.

أما بالنسبة للاتجاهات الصدرية Chest Leads – Precordial Leads فتشمل تسجيل النشاط الكهربائي في المستوى الأفقي، وتشمل الأقطاب المعيارية من V1 إلى V6 بالإضافة إلى الأقطاب غير المعيارية V7,V8,V9 التي تقع في مواقع خلفية. تتموضع هذه الأقطاب بدقة لتوفير تصوير شامل للنشاط الكهربائي، حيث أن V1 توجد عند الورب الرابع على الجانب الأيمن من القص، بينما تقع V2 عند الورب الرابع على الجانب الأيسر من القص، ويقع V3 بين V2 و V4، أما V4 فتكون عند الورب الخامس الأيسر على الخط منتصف الترقوة، و V5 على الورب الخامس الأيسر عند الخط الإبطي الأمامي، و V6على الورب الخامس الأيسر عند الخط الإبطي المتوسط، أما الأقطاب الخلفية V7 إلى V9 فتتموضع على الإبط والظهر لتوفير رؤية كاملة للجزء الخلفي من القلب.

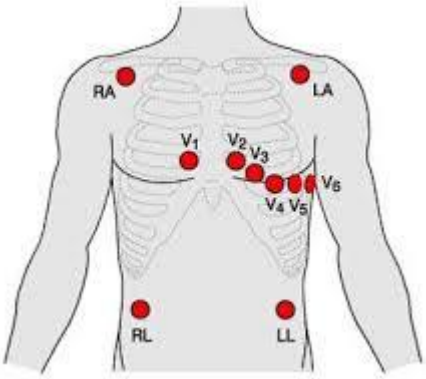

الشكل(5-3) توضع الأقطاب على جسم المريض أثناء اقتباس إشارة القلب.

تتوافق الأجزاء المختلفة للقلب مع مسارات محددة في تخطيط القلب الكهربائي، مما يتيح تقييم كل منطقة بدقة. فالبطين الأيمن يُقابل الأقطاب V1 و V2 و aVR، بينما يغطي الجدار الأمامي للقلب الأقطاب V1 و V2و V3 و V4 أما الجدار السفلي فيرتبط بالأقطاب II و III وaVF، في حين يمثل الجدار الجانبي الأقطاب I و aVL و V5و V6 وأخيراً تُغطي الأقطاب الخلفية V7 و V8 و V9 الجدار الخلفي للقلب، مما يوفر رؤية كاملة لجميع أجزاء العضلة القلبية من خلال تسجيل النشاط الكهربائي.

يُعد تخطيط القلب الكهربائي الأداة الأساسية لقياس النشاط الكهربائي للقلب، إذ تُلتقط التغيرات في فرق الكمون الكهربائي الناتج عن إزالة وإعادة الاستقطاب في خلايا عضلة القلب، ويعتمد نجاح هذه العملية على اختيار الطريقة المناسبة لالتقاط الإشارة، نوع الأقطاب المستخدمة، وطريقة تضخيم الإشارة ومعالجتها. يمكن تقسيم طرق اقتباس الإشارة القلبية إلى عدة مستويات رئيسية فبحسب عدد نقاط القياس

يمكن أن يقسم التخطيط إلى التخطيط القياسي Standard 12-Leads والتخطيط ذو الاتجاه الواحد أو الاتجاهات المحدودة Single/Reduce Leads، حيث يُستخدم تخطيط القلب ذو الاتجاه الواحد أو الاتجاهات المحدودة في الأجهزة المحمولة وأدوات المراقبة المنزلية، حيث يكتفي بقياس فرق الكمون بين نقطتين أو ثلاث نقاط، مثل I أو II ويشيع استخدام هذا النوع في الأجهزة الذكية القابلة للارتداء، بما في ذلك الساعات الذكية وأجهزة Holter، نظراً لما يتميز به من بساطة وسهولة في الاستخدام، ومع ذلك يتمثل عيبه في فقدان بعض المعلومات التشخيصية الدقيقة مقارنة بالتخطيط القياسي متعدد الاتجاهات.

6.3 طرق الاقتباس بحسب نوع الأقطاب المستخدمة:

1.6.3 الأقطاب اللاصقة Wet Electrodes Ag/AgCl:

تُعد الأقطاب اللاصقة الأكثر استخداماً تقليدياً في تخطيط القلب، حيث يتم تثبيتها على الجلد باستخدام مادة هلامية موصلة Electrolyte Gel، مما يضمن مقاومة تلامس منخفضة وبالتالي الحصول على إشارة كهربائية عالية الجودة. ومع ذلك، قد يؤدي الاستخدام الطويل لهذه الأقطاب إلى تهيج الجلد، كما أن جفاف المادة الهلامية مع مرور الوقت قد يؤثر على دقة القياس.

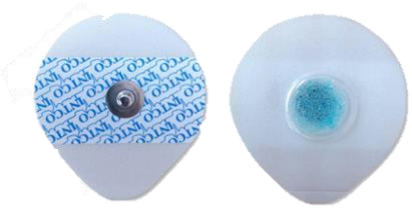

الشكل(6-3) الأقطاب اللاصقة Wet Electrodes.

2.6.3 الأقطاب من النوع الجاف Dry Electrodes:

هي أقطاب من النوع الذي لا تحتاج إلى مادة هلامية، وغالباً ما تصنع من معادن أو مواد موصلة متوافقة حيوياً. تتميز هذه الأقطاب بملاءمتها للأجهزة القابلة للارتداء والمراقبة المستمرة للنشاط الكهربائي للقلب، إلا أن أحد التحديات المرتبطة بها هو ارتفاع نسبة الضجيج Noise الناتج عن مقاومة التلامس الكبيرة مع الجلد، ما قد يؤثر على جودة الإشارة الكهربائية.

الشكل(7-3) الأقطاب الجافة.

3.6.3 الأقطاب النسيجية أو المدمجة في الملابس Textile/Smart Fabric Electrodes:

تُعد الأقطاب النسيجية أو المدمجة في الملابس نوعًا متقدماً من أقطاب تخطيط القلب، حيث تُدمج في المنسوجات أو الأقمشة القابلة للارتداء، مثل القمصان الذكية، وتتيح هذه التقنية المراقبة طويلة الأمد لنشاط القلب، مما يجعلها مناسبة للاستخدام من قبل الرياضيين أو مرضى القلب الذين يحتاجون إلى متابعة مستمرة، ومع ذلك فإن أحد التحديات المرتبطة بها هو حساسيتها للحركة والعرق، الأمر الذي قد يؤثر على جودة الإشارة الكهربائية المسجلة.

الشكل(8-3) الأقطاب المدمجة في الملابس.

4.6.3 الأقطاب السعوية Capacitive Coupling Electrodes:

نوع من أقطاب التخطيط التي تعمل دون تلامس مباشر مع الجلد، حيث تلتقط التغيرات الكهربائية عبر طبقة عازلة مثل الملابس أو الهواء الرقيق. تتميز هذه الأقطاب بفائدتها في التطبيقات غير الغازية، مثل مقاعد السيارات الذكية أو الأسرة الطبية، إلا أن أحد عيوبها يتمثل في ارتفاع نسبة الضجيج، ما يتطلب استخدام دوائر تضخيم ومعالجة متقدمة لضمان جودة الإشارة الكهربائية المسجلة.

الشكل(9–3) الأقطاب السعوية.

7.3 طرق الاقتباس بحسب بيئة الاستخدام:

1.7.3 أجهزة التخطيط السريرية Clinical ECG Machines:

تُعد أجهزة التخطيط السريرية من الأدوات المعتمدة في المستشفيات والعيادات، وغالباً ما تكون متعددة الاتجاهات 12-leads وتحتوي على وحدات تضخيم رقمية عالية الدقة، مما يتيح تسجيل النشاط الكهربائي للقلب بدقة كبيرة وتوفير معلومات تشخيصية موثوقة للأطباء.

2.7.3 أجهزة المراقبة المحمولة Holter Monitors:

تُعد أجهزة المراقبة المحمولة Holter Monitors من الأدوات المهمة لتسجيل النشاط الكهربائي للقلب بشكل مستمر لمدة تتراوح بين 24 و72 ساعة أو أكثر، وتُستخدم بشكل رئيسي للكشف عن اضطرابات النظم القلبية التي قد لا تظهر أثناء الفحص السريري القصير، مما يتيح متابعة دقيقة للحالة الكهربائية للقلب على مدى فترة طويلة.

الشكل(10-3) جهاز Holter.

3.7.3 الأجهزة القابلة للارتداء Wearable Devices:

تُعد الأجهزة القابلة للارتداء مثل الساعات الذكية، الأحزمة الطبية، والملابس الذكية، وسيلة حديثة لمراقبة النشاط الكهربائي للقلب بشكل مستمر وتعد أسلوباً غير مزعج للمريض، وغالباً ما تعتمد هذه الأجهزة على تخطيط القلب باتجاه واحد أو اتجاهين فقط، مما يجعلها مناسبة للاستخدام اليومي والمراقبة المستمرة خارج نطاق المستشفيات أو العيادات.

الشكل(11-3) ساعة ذكية.

4.7.3 أنظمة الاقتباس غير التلامسية Non-Contact Systems:

تُعد أنظمة الاقتباس غير التلامسية نوعاً من تقنيات مراقبة القلب التي يتم فيها قياس الإشارات الكهربائية دون ملامسة مباشرة للجلد، مثل الأنظمة المدمجة في الكراسي أو المراتب المزودة بمستشعرات سعوية. وتتميز هذه الأنظمة بفائدتها في المراقبة غير الغازية Non Invasive للأطفال وكبار السن أثناء النوم، مما يسمح برصد مستمر للنشاط القلبي دون التسبب بأي إزعاج للمريض.

8.3 معالجة الإشارة بعد الاقتباس:

بغض النظر عن الطريقة المتبعة لاقتباس الإشارة الكهربائية للقلب، تمر الإشارة بعد ذلك بمراحل معالجة أولية Pre-Processing لضمان دقة التحليل والتفسير، تبدأ هذه المراحل بالتضخيم Amplification لرفع شدة الإشارة لتصبح قابلة للمعالجة، يليها الترشيح Filtering لإزالة الضجيج الناتج عن حركة العضلات أو تداخل الشبكة الكهربائية عند 60/50 Hz، بعد ذلك يتم التحويل من القيم التماثلية إلى القيم الرقمية من خلال محول تماثلي رقمي Analog-Digital Converter ADC ما يجعلها قابلة للمعالجة بواسطة الحاسوب، ويتم العمل على إزالة الانحراف الأساسي Baseline wander[1]، واستخراج الميزات المهمة للإشارة، بما يضمن جودة البيانات وبالتالي جودة التحليل والتفسير الطبي الدقيق.

9.3 الإقفار القلبي Cardiac Ischemia:

هو حالة مرضية يحدث فيها نقص أو انقطاع التروية الدموية عن عضلة القلب بسبب انسداد أو تضيق في الشرايين التاجية التي تغذي القلب**[4]**، هذا النقص في التروية يؤدي إلى قلة وصول الأكسجين والمواد الغذائية اللازمة لعمل العضلة القلبية بشكل طبيعي، تشمل الأعراض السريرية لهذه الحالة ألماً ضاغطاً أو حارقاً في الصدر يُعرف بالذبحة الصدرية، وقد يمتد هذا الألم إلى الذراع الأيسر أو الرقبة أو الفك، كما قد يصاحبها ضيق في النفس، تعرق بارد، شعور بالدوار أو التعب العام، وتجدر الإشارة إلى أن بعض المرضى وخصوصًا مرضى السكري أو النساء قد تظهر عليهم الأعراض بشكل صامت أو غير نمطي، مما يستدعي اهتماماً خاصاً في التشخيص والمراقبة. يمثل الإقفار القلبي خطراً حقيقياً على حياة المريض، إذ يُعد مرحلة مبكرة من نقص التروية التاجية، وإذا لم يُعالج فقد يتطور إلى احتشاء كامل لعضلة القلب

[1] Baseline Wander أو انحراف خط الأساس: هو نوع من التشويش منخفض التردد يظهر غالباً في تخطيط القلب الكهربائي، وهو انحراف بطيء غير مرعوب فيه بحيث لا يبقى خط التساوي الكهربائي Isoelectric Line ثابتاً يل يتحرك لأعلى وأسفل بشكل متذبذب.

Myocardial Infarction، كما يرفع الإقفار خطر حدوث اضطرابات النظم البطينية القاتلة، مثل الرجفان البطيني Ventricular fibrillation، ويؤدي إلى تراجع كفاءة الضخ القلبي، مما قد ينتج عنه فشل قلبي أو صدمة قلبية إذا استمر دون علاج مناسب.

تظهر حالة الإقفار القلبي على مخطط القلب الكهربائي من خلال مجموعة من التغيرات المميزة، منها انخفاض مقطع ST/ ST Depression بشكل أفقي أو مائل للأسفل، وانعكاس موجة T/ T-wave Inversion، وفي بعض الحالات يلاحظ تسطح موجة T أو حدوث تغير ديناميكي لها مع الجهد أو الشعور بالألم، مما يساعد الأطباء في تشخيص وتقييم شدة الإقفار القلبي بشكل دقيق.

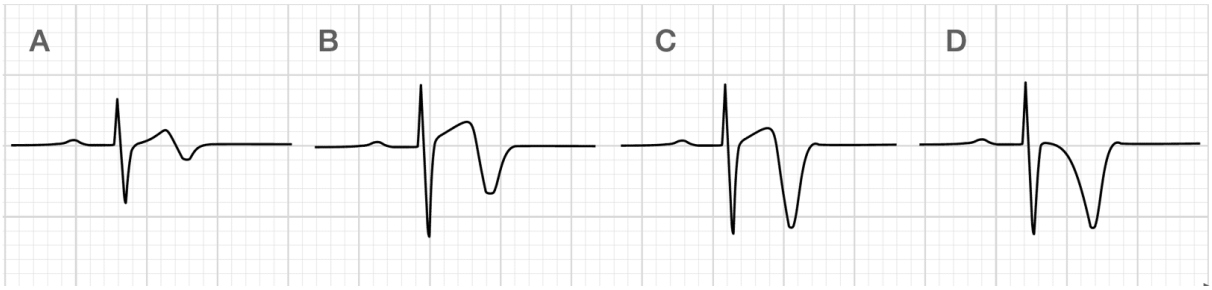

الشكل(12-3) شكل النبضة في مخطط القلب الكهربائي في حالة الإقفار القلبي.

10.3 تعريف الذكاء الصنعي Artificial Intelligence – AI:

يُعرّف الذكاء الصنعي بأنه قدرة الأنظمة الحاسوبية على محاكاة السلوك الذكي للبشر، من خلال تنفيذ مهام تتطلب عادةً مستوى من "الذكاء البشري" مثل: الإدراك، التعلم، التفكير، حل المشكلات، واتخاذ القرار. قد تطور الذكاء الصنعي منذ منتصف القرن العشرين من خوارزميات منطقية بسيطة إلى أنظمة معقدة قادرة على التعلم الذاتي بفضل التقدم في قدرات المعالجة الحاسوبية وتوفر البيانات الضخمة Big Data.

1.10.3 تعلم الآلة Machine Learning ML:

تعلم الآلة هو أحد فروع الذكاء الاصطناعي حيث يركز على تطوير خوارزميات وأنظمة تستطيع التعلم من البيانات واستخلاص الأنماط منها، ثم اتخاذ قرارات أو توقعات بشكل تلقائي دون أن تتم برمجتها بشكل صريح للقيام بهذه المهام، يعتمد على بناء نماذج تستند إلى ميزات يتم استخلاصها يدويًا Hand-crafted

features من البيانات بواسطة الخبراء، على سبيل المثال عند تحليل إشارات ECG، يقوم الباحث بتحديد الخصائص مثل ارتفاع موجة R أو طول الفترة PR قبل إدخالها إلى خوارزمية التعلم الآلي، مثل خوارزميات SVM أو Random Forest ، وتتمثل ميزة هذه الطريقة في بساطة النموذج وسرعة التدريب، بينما يكمن القصور في محدودية قدرتها على تمثيل الأنماط المعقدة وصعوبة تعميمها على بيانات جديدة.

2.10.3 التعلم العميق Deep Learning DL:

تعتمد تقنيات التعلم العميق على شبكات عصبية متعددة الطبقات قادرة على استخراج الميزات تلقائياً من البيانات الخام، دون الحاجة إلى تدخل بشري مباشر في اختيار الخصائص، وتتمثل ميزة هذه التقنية في قدرتها على اكتشاف أنماط خفية ومعقدة في البيانات الطبية، بينما يكمن القصور في حاجتها إلى مجموعات بيانات كبيرة وقوة حسابية عالية لضمان أداء دقيق وموثوق.

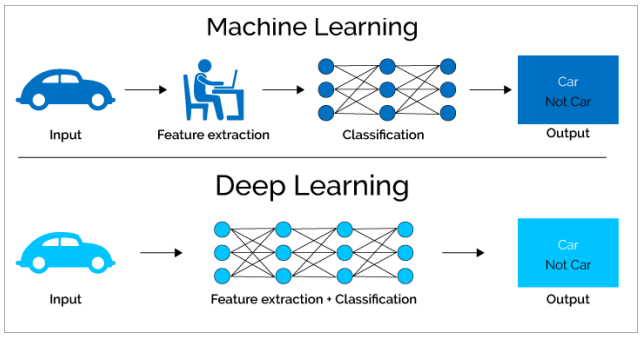

الشكل(13-3) الفرق بين التعلم الآلي والتعلم العميق.

الشبكات العصبية الاصطناعية Artificial Neural Networks ANN:

تُعد الشبكات العصبية الاصطناعية نماذج تعلم عميق Deep Learning Models مستوحاة من بنية الدماغ البشري، حيث تتألف من وحدات معالجة تُسمى العصبونات الاصطناعية Artificial Neurons مرتبة في طبقات تشمل طبقة الإدخال Input Layers، الطبقات المخفية Hidden Layers، وطبقة الإخراج Output Layer.

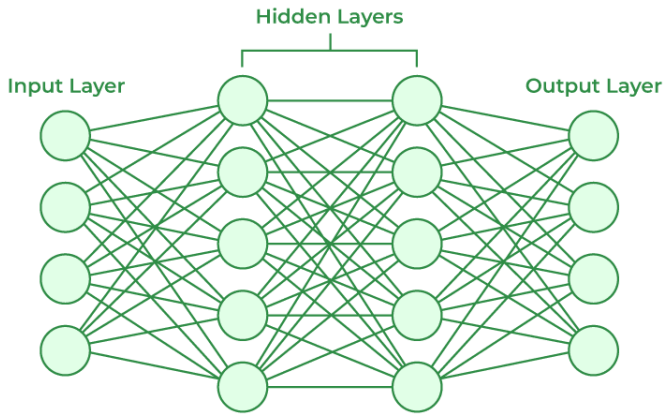

الشكل(14-3) بنية الشبكة العصبية الاصطناعية.

الشبكات العصبية الالتفافية Convolutional Neural Networks CNNs:

تُعد الشبكات العصبية الالتفافية نوعاً خاصاً من الشبكات العصبية الاصطناعية ANNs، صُممت خصيصاً لمعالجة البيانات ذات البنية الشبكية مثل الصور أو السلاسل الزمنية، تعتمد هذه الشبكات على طبقات التفاف Convolutional Layers لاستخراج الأنماط محلياً باستخدام مرشحات Filters، يليها طبقات تجميع Pooling Layers لتقليل الأبعاد مع الحفاظ على أهم الميزات، وفي النهاية يتم تمرير الميزات المستخلصة إلى طبقات Fully Connected لاتخاذ القرار، سواء كان تصنيفاً أو تنبؤً، مما يجعل CNN أداة قوية لتحليل البيانات الطبية المعقدة مثل إشارات ECG وصور الأشعة.

تتميز الشبكات العصبية الالتفافية بقدرتها على التعامل مع الإشارات الخام Raw signals مثل إشارات ECGدون الحاجة لاستخراج ميزات يدوية مسبقًا. كما تستطيع هذه الشبكات التعرف على الأنماط المكانية والزمانية المعقدة في الإشارة، وقد أظهرت نتائج دقيقة جدًا في اكتشاف اضطرابات النظم القلبي، احتشاء عضلة القلب، وحالات الإقفار، مما يجعلها أداة قوية وفعالة في التطبيقات الطبية التحليلية

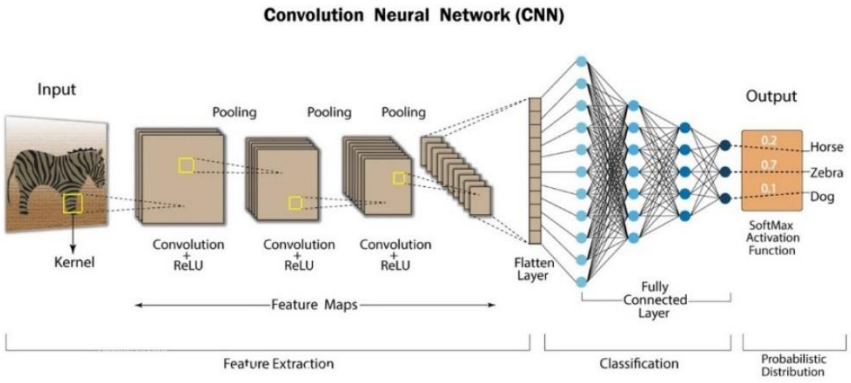

الشكل(15-3) بنية الشبكة العصبية الالتفافية.

قواعد بيانات الإشارات الحيوية:

هي مجموعات منظمة من البيانات التي تم جمعها من أجهزة طبية أو حساسات حيوية، مثل أجهزة تخطيط القلب، وتخطيط الدماغ، والموجات فوق الصوتية، وأجهزة قياس ضغط الدم، وغيرها. تُستخدم هذه البيانات لتدريب وتحليل النماذج الحسابية، وتطوير خوارزميات الكشف والتشخيص، وتحسين جودة الرعاية الصحية. تتمثل أهمية قواعد البيانات في مجال الهندسة الطبية الحيوية في عدة جوانب رئيسية، إذ تمكّن الباحثين من دراسة وتحليل الإشارات الحيوية لفهم الأنماط البيولوجية والتشخيصية، كما تُستخدم هذه القواعد لتدريب الخوارزميات الطبية على التمييز بين الحالات الصحية المختلفة، مثل الكشف المبكر عن الأمراض، مما يسهم في تحسين دقة التشخيص وسرعة الاستجابة الطبية، وبالتالي رفع مستوى جودة الرعاية الصحية. ومن الأمثلة على قواعد البيانات قاعدة بيانات PTB-XL التي تُعد من أكبر قواعد بيانات ECG الحديثة، إذ تضم أكثر من 21 ألف تسجيل من آلاف المرضى مع تشخيصات مشروحة سريرياً، إضافةً إلى قاعدة بيانات St. Petersburg INCART 12-lead Arrhythmia Database التي توفر تسجيلات لـ 12 اتجاه لمرضى مصابين باضطرابات نظم قلبية، والعديد من قواعد البيانات هذه متوفرة على موقع Phisyonet. تُستخدم قواعد البيانات في العديد من التطبيقات العملية، منها تطوير أنظمة المراقبة الذكية لمتابعة المرضى عن بُعد وتحليل حالتهم الصحية، وكذلك تدريب نماذج الذكاء الاصطناعي على التعرف على الأنماط المرضية المختلفة لتحسين دقة التشخيص، كما تُستخدم هذه القواعد في الدراسات البحثية لفهم الأمراض وتطوير علاجات جديدة، مما يسهم في تعزيز البحث العلمي وتحسين جودة الرعاية الصحية

الفصل الرابع

القسم العملي

Practical Part

4 الفصل الرابع

القسم العملي

Practical Part

1.4 مقدمة:

سنوضح في هذا الفصل المخطط الصندوقي للجهاز، فمن الجانب العتادي سيتم شرح آلية عمل الجهاز، والمكونات والأجزاء الرئيسية له، ومن الجانب البرمجي فسيتم شرح قواعد البيانات المستخدمة وسبب استخدامنا لها، وخوارزميات كشف قمم الموجات R وخوارزميات تقطيع النبضات، وشرح المكتبة WaveForm DataBase WFDB التي تتيح لنا مختلف قراءة الإشارات الحيوية Bio Signals، وبنية الشبكات العصبية المستخدمة في عمليات تصنيف النبضات، وشرح آلية الربط بين القسم العتادي والقسم البرمجي من خلال لوحة التطوير Raspberry Pi 4.

2.4 مخطط العمل:

يبين المخطط الصندوقي المراحل الأساسية لمشروع الكشف عن الإقفار القلبي عن طريق التعلم العميق وذلك من خلال اقتباس إشارة القلب. يبدأ المخطط بمرحلة التقاط إشارة القلب (ECG) باستخدام المجسات الحيوية، تليها المعالجة المسبقة للإشارة بهدف إزالة الضوضاء وتحسين جودتها. بعد ذلك تُمرَّر الإشارة المعالجة إلى نموذج التعلم العميق الذي يقوم بتحليلها واستخراج الخصائص ذات الصلة، ليتم في الخطوة التالية تصنيفها وتشخيصها وفقاً لوجود أو غياب مؤشرات الإقفار القلبي. وأخيراً تُعرض النتيجة النهائية للتشخيص على الشاشة بشكل واضح ودقيق. يمثل هذا المخطط الصندوقي تصوراً علمياً لتسلسل العمليات التي تضمن موثوقية التشخيص ودقته.

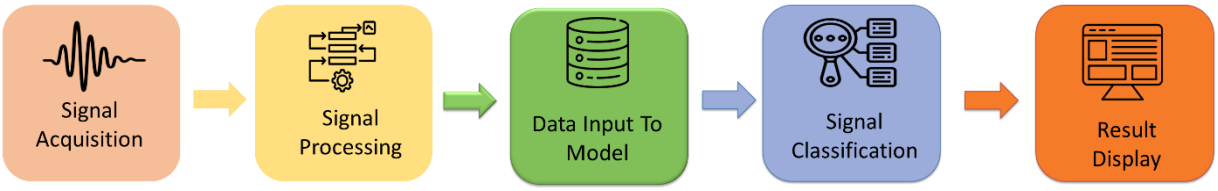

الشكل(1-4) المخطط الصندوقي للجهاز.

3.4 العتاد المادي:

1.3.4 حساس تخطيط القلب AD8232:

حساس اقتصادي غير مكلف، يستخدم لقياس النشاط الكهربائي للقلب من خلال اقتباس وقياس هذ النشاط، الأمر الذي يتيح إمكانية تخطيطه بيانياً وعرض قيم القراءات كقراءة تماثلية، كما ويعمل هذا الحساس كمضخم عملياتي Operational Amplifier OP-AMP للمساعدة في الحصول على إشارة واضحة لفترات PR وQT بسهولة. يُعد الحساس AD8232 قطعة متكاملة لمعالجة الإشارة في تطبيقات مخطط القلب الكهربائي وقياس الجهد الحيوي، حيث تم تصميمه لاستخراج الإشارات الحيوية الصغيرة وتضخيمها وترشيحها، خصوصاً في حالات الضجيج الناتج عن الحركة أو سوء توضع الأقطاب البعيدة.

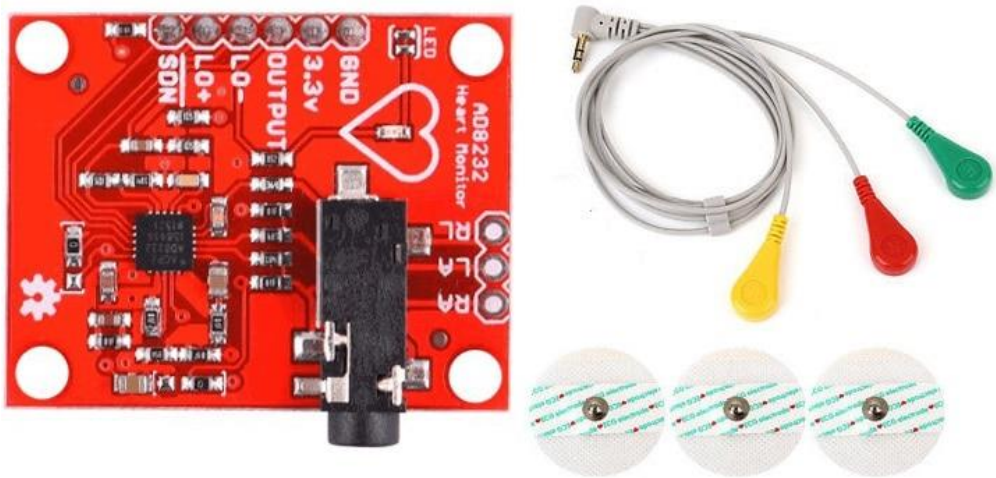

الشكل(2-4) حساس تخطيط القلب AD8232.

تتكون الوحدة الأساسية للحساس من دارة متكاملة Integrated Circuit IC تضم تسعة أطراف توصيل يمكن ربطها إما عبر لحام مباشر للأسلاك أو باستخدام توصيلات مخصصة، تشمل الأطراف الأساسية اللازمة لتشغيل الحساس كلّاً من SDNو+LO، و-LO، وOUTPUT، بالإضافة إلى خط التغذية 3.3V وخط الأرضي GNDويمكن تشغيل هذه الوحدة بسهولة من خلال ربطها بلوحة تطوير مثل Arduinoأو أي منصة تطوير أخرى متوافقة. كما وأن الحساس مزود بأرجل مخصصة لربط الحساسات وهي الذراع اليمنى RA - Right Arm، الذراع اليسرى LA - Left Arm، الساق اليمنى RL - Right Leg. يحتوي اللوح على مؤشر ضوئي LED ينبض بإيقاع ضربات القلب. تمر الإشارة المقتبسة من القلب من خلال الحساس بعدة مراحل:

- تضخيم الإشارة الصغيرة.
- إزالة الانحراف DC offset والضوضاء المنخفضة التردد.
- إزالة الضجيج العالي التردد.
- إخراج إشارة ECG نظيفة نسبياً كموجة يمكن قراءتها على المتحكم أو عرضها على راسم الإشارة Oscilloscope.

إن المواصفات الفنية الأساسية Key Specifications للحساس تتمثل في أن نطاق جهد التغذية يتراوح بين 2 وحتى 3.5 فولت عادةً، مع استهلاك طاقة منخفض جداً، الأمر الذي يجعله مناسباً للأجهزة القابلة للارتداء، يخرج الحساس إشارة تماثلية Analog Singal ويمكن ربطه بسهولة مع وحدات مثل Arduino و ESP32 و Raspberry Pi عبر مدخل ADC معدل، أما بالنسبة لنسبة الربح Gain فهي قابلة للضبط حسب التوصيف الداخلي ويتراوح عادةً بين 40 و100، بينما تبلغ أبعاد اللوحة التجارية حوالي 22×35 ميليمتر.

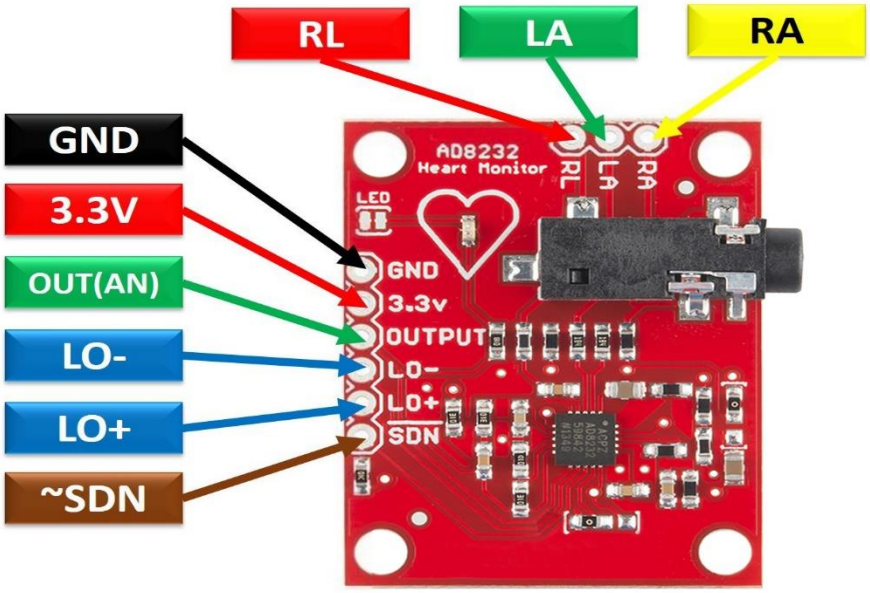

الشكل(3-4) أطراف الحساس AD8232.

توضع حساس تخطيط القلب AD8232 على الجسم:

كلما كانت مواضع الأقطاب أقرب إلى القلب كان القياس أوضح وأكثر دقة، عادةً ما تكون الكابلات مميزة بألوان تسهّل التعرف على أماكن التوصيل، حيث يشير اللون الأحمر إلى القطب RA الخاص بالذراع اليمنى، بينما يشير اللون الأصفر إلى القطب LA على الذراع اليسرى، واللون الأخضر إلى القطب RL الذي يوضع على الساق اليمنى، يتميز حساس AD8232 بدعمه لخاصية Lead-Off Detection التي تسمح بالكشف عن فصل الأقطاب، ومع ذلك فإن من أبرز عيوبه هي حساسيته العالية للضوضاء وخاصة الناتجة عن حركة العضلات، وحاجته إلى تطبيق مرشحات إضافية سواء برمجية أو عتادية للحصول على إشارات أكثر نقاءً، كما أنه لا يعد جهازاً طبياً معتمداً وإنما مناسب أكثر للأبحاث والتطبيقات التعليمية.

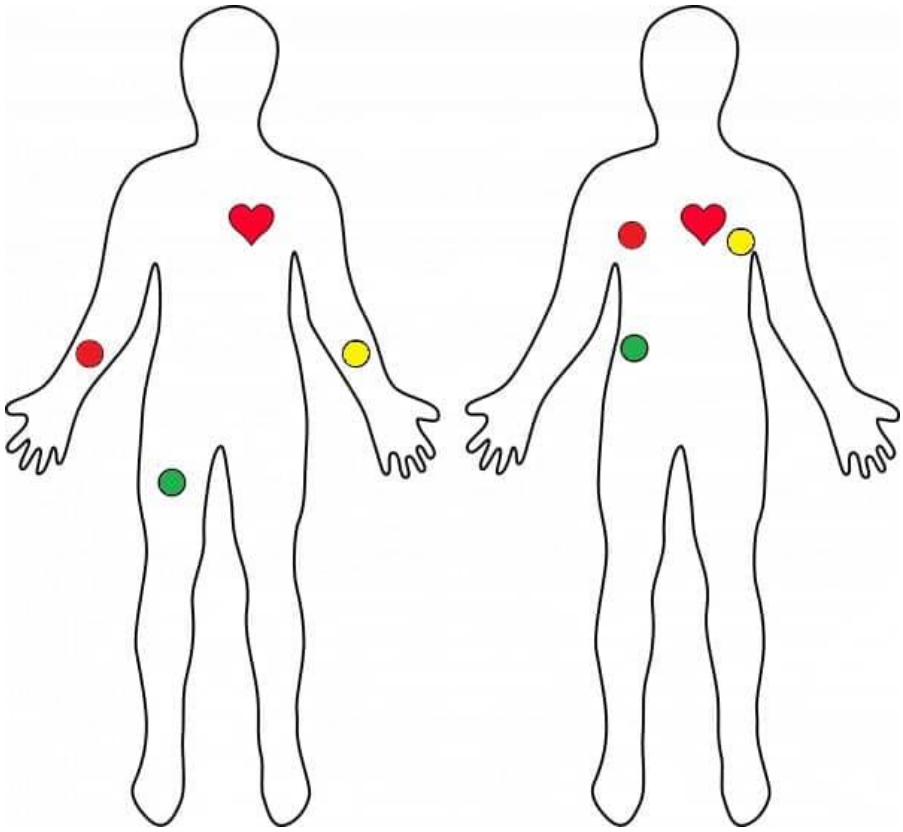

الشكل(4-4) توضع حساس تخطيط القلب AD8232 على الجسم.

2.3.4 لوحة التطوير Raspberry Pi 4 Model B:

تُعتبر لوحة Raspberry Pi 4 Model B من أشهر الحواسيب المصغّرة Single Board Computers SBCs التي طُورت من قبل مؤسسة Raspberry Pi في المملكة المتحدة، وتهدف إلى توفير منصة منخفضة التكلفة وعالية الكفاءة لتشجيع التعليم والابتكار في مجال الإلكترونيات والبرمجة.

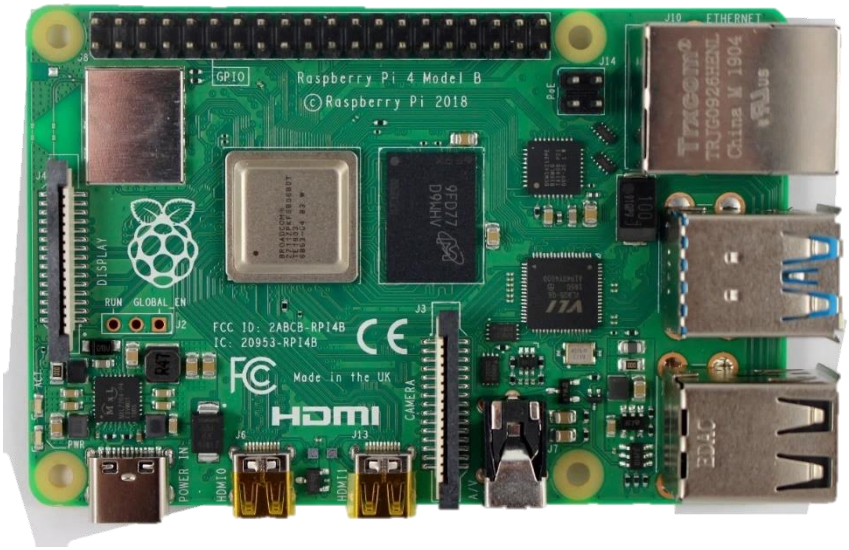

الشكل(5-4) لوحة Raspberry Pi 4 Model B.

منذ إصدارها عام 2019، أصبحت هذه اللوحة خياراً رئيسياً في الأبحاث الأكاديمية والتطبيقات العملية التي تتطلب قدرة معالجة جيدة مع حجم صغير واستهلاك طاقة منخفض.

تتضمن المواصفات التقنية الأساسية للوحة Raspberry Pi 4 معالجاً رباعي النواة من نوع ARM Cortex-A72 بتردد 1.5GHz، وذاكرة وصول عشوائي RAM بسعة 2GB من نوع LPDDR4، بالإضافة إلى معالج رسومي VideoCore VI قادر على تشغيل الفيديوهات بدقة 4K، أما منافذ الاتصال فتشمل منفذي micro HDMI، ومنفذين USB 3.0، ومنفذين USB 2.0، ومنفذ Gigabit Ethernet، بالإضافة إلى واجهة GPIO مؤلفة من 40 طرف Pin يمكن استخدامها مع الحساسات والوحدات الإلكترونية المختلفة. يدعم التخزين عبر بطاقة microSD، كما يوفّر اتصالاً لاسلكياً من خلال Wi-Fi بمعيار 802.11ac و Bluetooth 5.0. تعمل اللوحة بجهد تغذية 5V/3A عبر منفذ USB-C. من أبرز المميزات التي تجعل لوحة Raspberry Pi 4 مناسبة للأبحاث صغر حجمها الذي يسهل دمجها في الأجهزة الطبية أو النظم المدمجة، إضافة إلى

مرونتها العالية في التوصيل مع عدد كبير من الحساسات والوحدات الإلكترونية. كما تتميز بدعمها لأنظمة تشغيل متعددة مثل Raspberry Pi OS و Ubuntu، وبتوافر مجتمع عالمي ضخم يقدّم دعماً علمياً وتقنياً مفتوح المصدر، يضاف إلى ذلك انخفاض استهلاكها للطاقة مقارنة بالحواسيب التقليدية، مما يجعلها خياراً عملياً وفعالاً في البيئات البحثية والتجريبية. تحتوي جميع طرازات Raspberry Pi على منفذ USB مشابه للمنفذ الموجود في معظم الهواتف المحمولة، وذلك للتوصيل مع مأخذ طاقة كهربائية حيث يكون منفذ USB إما من النوع C في الجيل الرابع من Raspberry Pi. يحتاج Raspberry Pi إلى بطاقة تخزين SD لتخزين جميع الملفات ونظام التشغيل الخاص عليه، حيث ستحتاج بطاقة تخزين microSD بسعة 8 غيغابايت على الأقل.

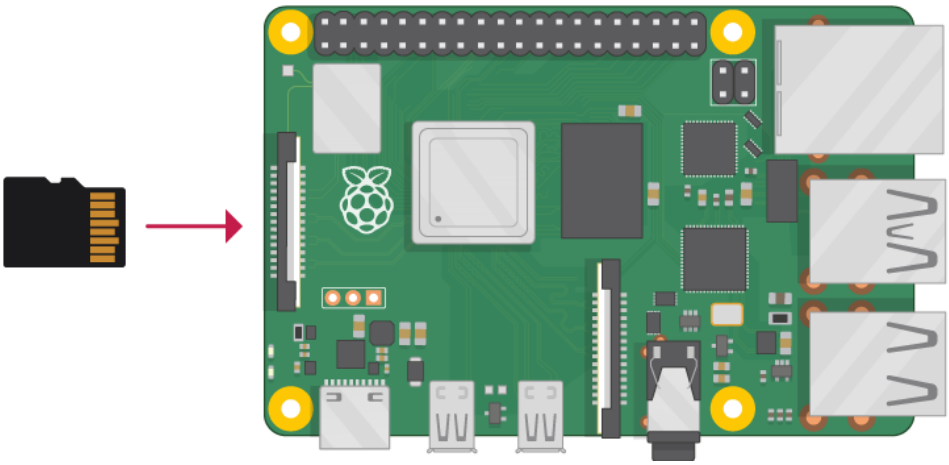

الشكل(6-4) بطاقة تخزين من نوع MicroSD.

تثبيت نظام التشغيل Raspberry Pi OS باستخدامRaspberry Pi Imager:

لتشغيل لوحة Raspberry Pi 4B لا بد من تثبيت نظام تشغيل مناسب، ويُعد Raspberry Pi OS المعروف سابقًا باسم Raspbian النظام الأكثر استخداماً، وهو نسخة معدلة من نظام Linux (Debian) ومصمم خصيصاً للعمل على لوحات Raspberry Pi، أبسط طريقة لتثبيته تتم عبر الأداة الرسمية Raspberry Pi Imager، في البداية يتم تنزيل البرنامج من الموقع الرسمي لمؤسسة Raspberry Pi، وهو متاح لأنظمة Windows و macOS و Linux بعد ذلك يتم توصيل بطاقة الذاكرة microSD بالحاسوب عبر قارئ بطاقات، ثم فتح البرنامج واختيار نظام التشغيل المناسب مثل Raspberry Pi OS (32-bit) من خلال خيار "Choose OS" بعد تحديد النظام يتم اختيار وسيط التخزين من خلال "Choose Storage" حيث تُحدد

البطاقة المتصلة، ثم الضغط على "Write" ليقوم البرنامج بتنزيل نسخة النظام ونسخها تلقائياً على البطاقة، عند انتهاء العملية يتم إدخال بطاقة microSD في اللوحة Raspberry Pi 4B وتشغيلها عبر منفذ الطاقة USB-C ليبدأ النظام بالإقلاع مباشرة.

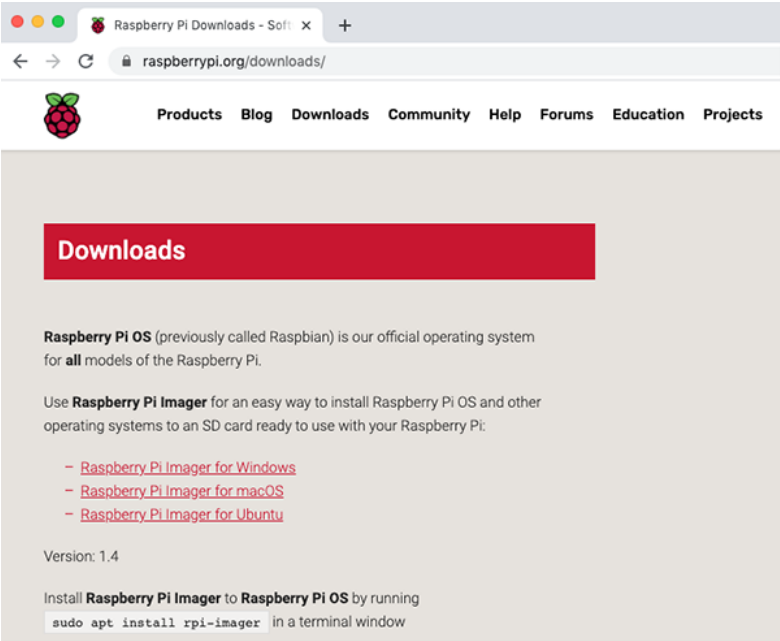

الشكل(7-4) الموقع الرسمي لتحميل نظام Raspberry Pi.

يُوصى بتوصيل جميع المكونات مع لوحة Raspberry Pi بعناية، مع الالتزام بترتيب التوصيلات الصحيح لضمان سلامة الدارة وحماية الأجهزة من أي أعطال محتملة. بعد إتمام عملية التوصيل يتم إدخال بطاقة التخزين microSD المُهيأة مسبقاً بنظام التشغيل Raspberry Pi OS في المنفذ المخصص لها في الجهة السفلية من اللوحة.

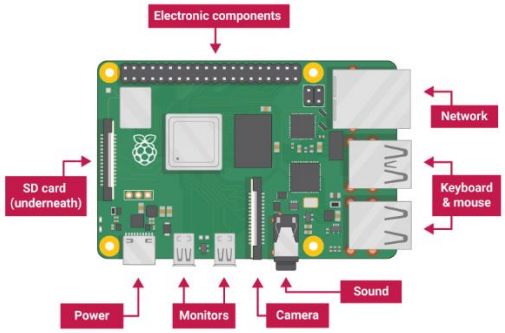

الشكل(8-4) أطراف لوحة Raspberry Pi.

نظرًا لعدم احتواء اللوحة على مفتاح تشغيل مدمج، فإنها تبدأ بالعمل مباشرة عند توصيلها بمصدر الطاقة عبر منفذ USB-C عندها يبدأ النظام بالإقلاع بشكل تلقائي إيذانًا ببدء تشغيل لوحة Raspberry Pi. عند تشغيل Raspberry Pi لأول مرة، سيظهر تطبيق Welcome to Raspberry Pi ليُرشدك إلى خطوات الإعداد الأولية.

الشكل(9–4) رسالة الترحيب عند تشغيل النظام.

بعد الانتهاء من إعداد الشبكة، يمكن تفعيل ميزة Virtual Network Computing VNC للتحكم بلوحة Raspberry Pi عن بُعد باستخدام جهاز الحاسوب الشخصي، يتم ذلك من خلال فتح إعدادات التفضيلات (Preferences → Raspberry Pi Configuration)، الانتقال إلى تبويب Interfaces وتفعيل خيار VNC، ثم تثبيت برنامج VNC Viewer على الحاسوب المضيف وإدخال عنوان الـ IP الخاص بلوحة Raspberry Pi للاتصال بها، بمجرد الاتصال يصبح بإمكان المستخدم الوصول الكامل إلى واجهة سطح المكتب الخاصة باللوحة، بما في ذلك تشغيل التطبيقات، مراقبة الإشارات، وإدارة الملفات دون الحاجة لربط لوحة مفاتيح أو شاشة مباشرة باللوحة.

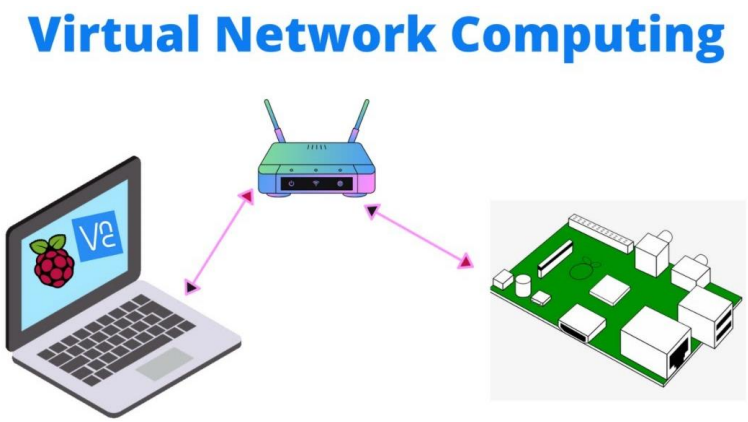

الشكل(10-4) ربط واجهة المتحكم بالحاسوب.

تُعد ميزة VNC أداة مهمة جداً في مشاريع الأجهزة الطبية والبحثية، لأنها تقلل الحاجة إلى التوصيلات المباشرة، مما يخفف من التعقيد أثناء إعداد الأجهزة والتجارب، كما أنها تسمح بالمراقبة والتحكم عن بُعد في الوقت الحقيقي Real-Time Monitoring، الأمر الذي يسهل اختبار الأجهزة القابلة للارتداء أو الأنظمة المدمجة دون التأثير على قياسات الحساسات أو الحركة الطبيعية للمستخدم، بالإضافة لذلك توفر VNC مرونة أكبر في إدارة بيانات المرضى أو الإشارات الحيوية، حيث يمكن تشغيل وتحليل البيانات من أي مكان مع الحفاظ على دقة وسلامة التجربة.

3.3.4 ADS1115 Analog-to-Digital Converter:

يُعتبر ADS1115 محولاً تماثلي رقمي ADC عالي الدقة، بدقة 16 بت، ويتميز باستهلاك منخفض للطاقة وصغير الحجم، ما يجعله مناسباً لتطبيقات القياس الدقيقة مثل مراقبة إشارات القلب والمشاريع العلمية والهندسية الأخرى، يدعم ADS1115 أربعة مداخل تماثلية يمكن تشغيلها كمدخلات فردية أو تفاضلية، ويتواصل مع المتحكمات الدقيقة عبر واجهة I^2C، مما يسهل دمج عدة وحدات في النظام نفسه.

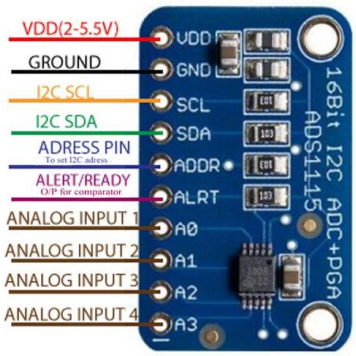

الشكل(11-4) ADS1115.

الخاصية	القيمة / الوصف
الدقة	16بت
معدل أخذ العينات(SPS)	8 – 860عينة/ثانية، قابل للبرمجة
عدد المداخل	4مداخل تماثلية (أو مدخلان تفاضليان)
الواجهة	I2C، مع إمكانية تحديد عنوان لكل وحدة
مكبر التضخيم القابل للبرمجة (PGA)	1×، 2×، 4×، 8×، 16×
جهد التشغيل	2.0 – 5.5 فولت
استهلاك الطاقة	منخفض جدًا، مناسب للأجهزة المحمولة والقابلة للارتداء
الدقة المرجعية	±0.5 LSB (typical)
الحزمة	VSSOP-10أو QFN-10
التطبيقات	مراقبة ECG القياسات العلمية الدقيقة، الأتمتة الصناعية، مشاريع الإلكترونيات الدقيقة

تحتوي وحدة ADS1115 على عشرة دبابيس رئيسية تُستخدم لتغذية الوحدة، توصيل المداخل التماثلية، والتواصل مع المتحكم عبر واجهة I2C، تصميم هذه الدبابيس يتيح مرونة كبيرة في الربط مع عدة أجهزة، كما يدعم إمكانية ضبط العنوان لكل وحدة لتشغيل عدة وحدات على نفس الخط، ويشمل دبوساً خاصاً للإشارات التنبيهية (ALRT) التي تفيد في تطبيقات القياس الدقيقة والتنبيه عند تجاوز القيم المحددة مسبقاً، الجدول التالي يوضح وظيفة كل دبوس بالتفصيل:

الدبوس(Pin)	الاسم	الوظيفة
1	ADDR	تحديد عنوان I²C للوحدة (يمكن تغييره لتوصيل عدة وحدات)
2	A0	مدخل تماثلي رقم 0
3	A1	مدخل تماثلي رقم 1
4	A2	مدخل تماثلي رقم 2
5	A3	مدخل تماثلي رقم 3
6	GND	الأرضي (0 فولت)
7	VDD	جهد التشغيل (2.0 – 5.5 فولت)
8	SCL	خط الساعة لواجهةI²C
9	SDA	خط البيانات لواجهةI²C
10	ALRT	خرج تنبيه (اختياري) لإشارات تجاوز الحد المبرمج

4.3.4 شاشات O-LED:

تُستخدم شاشات O-LED في مشاريع الإلكترونيات الصغيرة مع المتحكمات الدقيقة، وغالباً تأتي هذه الشاشات بمقاسات صغيرة مثل 0.96 إنش أو 1.3 إنش، مع دقة عرض تصل إلى 128×64 أو 128×32 بكسل. وعلى عكس شاشات LCD التي تقتصر على عرض النصوص والأرقام فقط، تتيح شاشات OLED عرض محتويات متنوعة، بما في ذلك النصوص والأرقام، والأيقونات والرسوم البيانية، والرسومات البسيطة مثل الشعارات والأشكال الهندسية.

غالبية شاشات OLED تعتمد على واجهة الاتصال I2C، وهي الأكثر شيوعاً حيث تتطلب هذه الواجهة أربعة أطراف فقط للعمل، وهي VCC الذي يمثل خط التغذية بجهد 3.3V أو 5V، وGND الذي يمثل خط الأرضي، وSCL وهو خط الساعة المسؤول عن تزامن الإشارة، وأخيراً SDA الذي يمثل خط البيانات لنقل المعلومات بين الشاشة والمتحكم.

الشكل(4-12) شاشة O-LED.

تمتاز شاشات OLED بأنها لا تحتاج إلى إضاءة خلفية مما يقلل استهلاك الطاقة، وتوفر ألواناً أكثر وضوحاً وتبايناً أعلى مقارنة بالشاشات التقليدية، كما تتيح عرض الرسومات والأشكال إلى جانب النصوص، ويُعتبر استهلاكها للطاقة منخفضاً بشكل خاص عند عرض النصوص باللون الأبيض على خلفية سوداء.

يعرض الشكل آلية عمل دارة تخطيط القلب باستخدام حساسين من نوع AD8232، حيث يتم توصيل ثلاثة أقطاب لكل حساس، يقوم الحساس الأول بالتقاط الإشارة وتوليد Lead I بينما يقوم الحساس الثاني بتوليد Lead II وفق مواضع الأقطاب على جسم المريض، بعد ذلك يتم تضخيم الإشارات الحيوية الضعيفة وترشيح الضوضاء الناتجة عن الحركة أو التداخل الكهربائي، ليتم إرسال الخرج التماثلي لكل حساس إلى لوحة Raspberry Pi 4B عبر مداخل ADC.

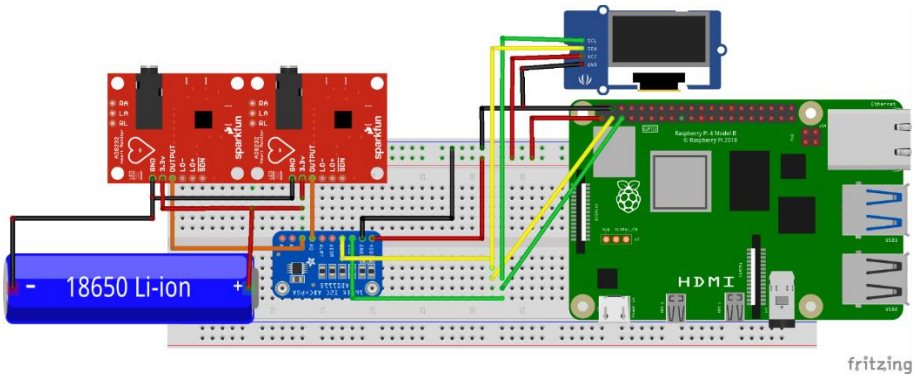

الشكل(4-13) مخطط يوضح مكونات دارة اقتباس الإشارة. (تم تصميمها باستخدام برنامج Fritzing)

تتم معالجة الإشارات في Raspberry Pi وتحويلها برمجياً إلى Lead II، Lead III، وaVF، ثم يتم عرضها بشكل مباشر على الشاشة Real-Time ECG Display لمراقبة حالة القلب لحظياً، بعد ذلك تطبق وحدة المعالجة خوارزميات التعلم العميق على هذه الإشارات من أجل تحليلها واستخراج الخصائص المهمة وتشخيص احتمالية الإصابة بمرض الإقفار القلبي بشكل آلي ودقيق، وتُعرض نتيجة التشخيص بشكل واضح على شاشة OLED المدمجة مع النظام، مع إمكانية تخزين النتائج لمراجعتها لاحقاً.

5.3.4 برنامج Fritzing:

يُعد Fritzing بيئة برمجية مفتوحة المصدر Open Source موجهة نحو دعم التعليم والبحث في مجال الإلكترونيات والتصميم الهندسي، تم تطويره خصيصاً لتبسيط عملية الانتقال من النموذج الأولي المبني على ألواح التجارب Breadboards إلى مخططات إلكترونية احترافية يمكن تصنيعها كلوحات مطبوعة Printed Circuit Boards PCB.

يتميّز البرنامج بواجهة رسومية سهلة الاستخدام، تسمح للمستخدم بتمثيل الدارات الإلكترونية بثلاثة أوضاع رئيسية: وضع اللوحة التجريبية Breadboard View يوفر تمثيلاً بصرياً عملياً لعملية توصيل العناصر الإلكترونية على لوحة التجارب، مما يساعد المبتدئين على فهم التوصيلات بشكل واضح. وضع المخطط الكهربائي Schematic View يمكّن من رسم المخطط الدائري الرسمي باستخدام الرموز القياسية للعناصر الإلكترونية، وهو ما يسهل قراءة الدارة وتوثيقها بطريقة أكاديمية. وضع اللوحة المطبوعة PCB View يسمح بتصميم لوحات دوائر مطبوعة ثنائية أو متعددة الطبقات، مع إمكانية تحديد المسارات النحاسية وتوزيع العناصر، تمهيداً لتصنيعها فعلياً. إضافة إلى ذلك يدعم Fritzing مكتبة واسعة من العناصر الإلكترونية الشائعة مثل المقاومات، المكثفات، الحساسات، المتحكمات الدقيقة كـ Arduino و Raspberry Pi، كما يتيح للمستخدمين إنشاء عناصر جديدة وتخصيصها، ويقدّم البرنامج كذلك أداة لمحاكاة التوصيلات بشكل بصري، مما يقلل من احتمالية وقوع الأخطاء في مراحل التصميم المبكر.

الشكل(14-4) شعار برنامج Fritzing.

تم استخدام برنامج Fritzing في محاكاة الدارة الأولية أثناء تركيبها على لوح الاختبار Breadboard، انظر الشكل(15-4)

6.3.4 برنامج EasyEda:

يُعد برنامج EasyEDA من البرمجيات المتقدمة في مجال تصميم الدارات الإلكترونية وتحليلها، ويُستخدم على نطاق واسع في الأوساط الأكاديمية والتعليمية والصناعية لكونه يجمع بين أدوات تصميم المخططات الكهربائية Schematic Capture، وتصميم لوحات الدوائر المطبوعة PCB Layout، وتحليل الدارات باستخدام المحاكاة (Circuit Simulation ضمن بيئة متكاملة تعتمد على الويب، دون الحاجة إلى تنصيب محلي. يتميز EasyEDA بواجهة رسومية تفاعلية تسهّل على المستخدمين إنشاء الدارات الكهربائية بأنواعها المختلفة، بدءًا من الدارات البسيطة وصولًا إلى الأنظمة الإلكترونية المعقدة متعددة الطبقات.

ويحتوي البرنامج على مكتبة ضخمة من العناصر الإلكترونية الجاهزة (مثل المقاومات، المكثفات، المتحكمات الدقيقة، الترانزستورات، الدارات المتكاملة)، بالإضافة إلى إمكانيات استيراد مكتبات خارجية أو إنشاء رموز مخصصة، مما يتيح حرية تامة في التصميم، كما يوفر البرنامج بيئة تصميم متقدمة للوحات PCB، تشمل تحديد طبقات النحاس، تحديد المسارات، التخطيط التلقائي، التحكم في التباعد، والتصميم وفق معايير التصنيع. ومن أبرز ما يميز EasyEDA هو ارتباطه بمنصة تصنيع مباشرة JLCPCB، ما يتيح للمستخدم إرسال التصميمات للطباعة والإنتاج بسرعة وسهولة.

الشكل(4-16) شعار برنامج EasyEda.

تم استخدام برنامج EasyEda لرسم مخطط الدارة Schematic الخاص بدارة الاقتباس، وتم توصيل مسارات الدارة ضمن البرنامج لطباعة لوح الدارة الإلكترونية المطبوعة Printed Circuit Board PCB.

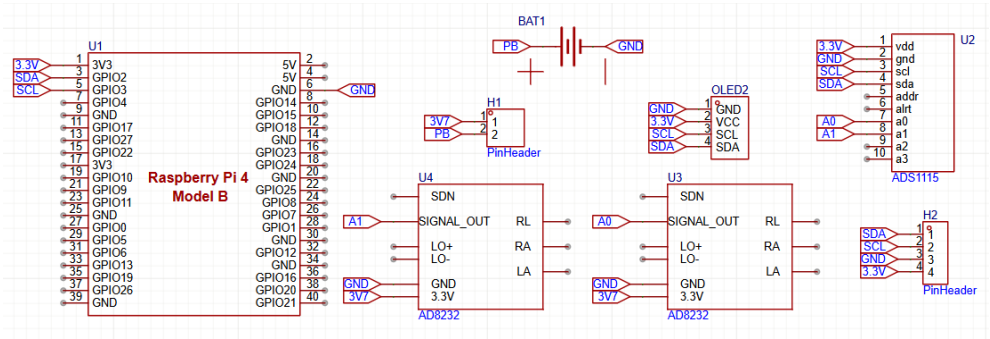

الشكل(4-17) مخطط الدارة الكلي، تم تصميمه باستخدام برنامج EasyEDA.

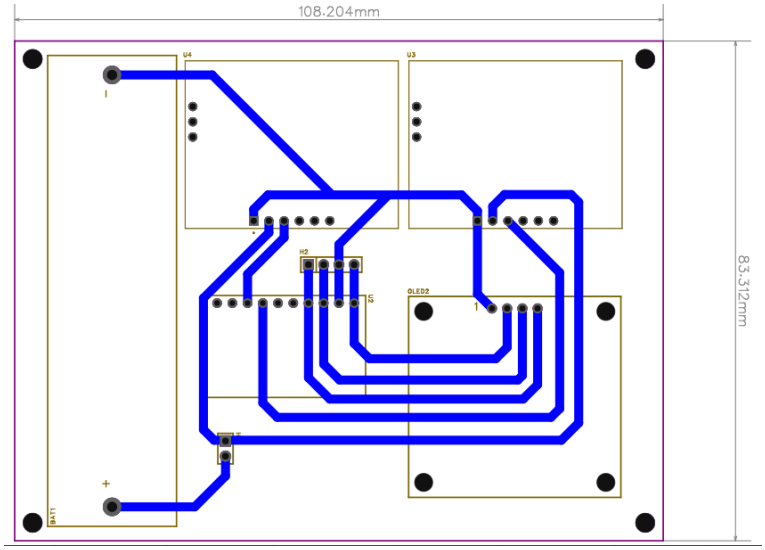

الشكل(4-18) توصيل الدارة الكلي، وتصميمها من أجل مرحلة طباعة دارات PCB.

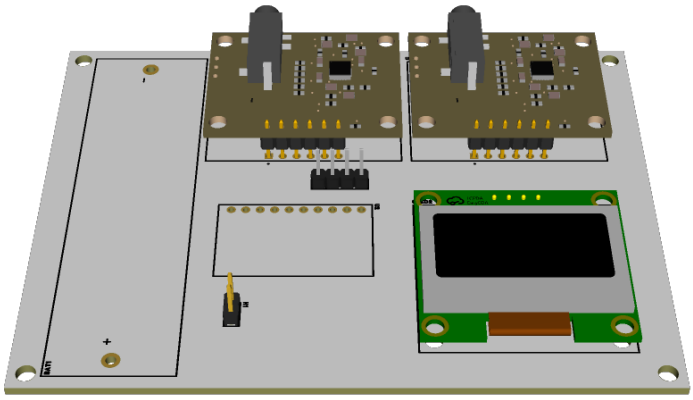

الشكل(19-4) مظهر الدارة وترتيب العناصر بشكل ثلاثي الأبعاد.

بعد تصميم مخطط PCB Layout على برنامج EasyEda، تم تصنيع الدارة بشكل يدوي من خلال ألواح نحاس تم قصها بحيث تساوي أبعاد الدارة المصممة 108×83 ميليمتر، وتم طباعة مخطط PCB Layout على ورق أصفر خاص بالتصوير، تم نقل المخطط من الورق الأصفر إلى لوح النحاس ذو الطبقة الواحدة من خلال التسخين والصدمة الحرارية، وتم تحميض الدارة باستخدام مادة كلوريد الحديديك التي تستخدم كمحلول حفر لإذابة النحاس من سطح اللوح، توضح الصور التالية آلية التصنيع بدءاً من المراحل الأولى:

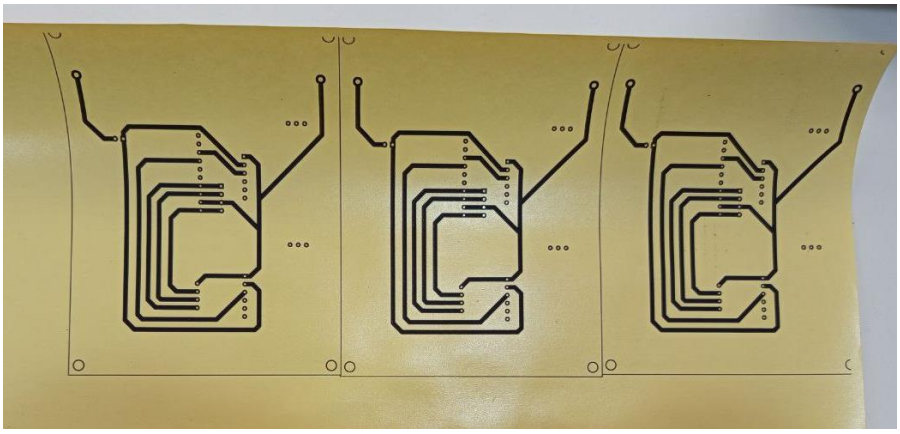

الشكل(20-4) طباعة مسارات PCB Layout على ورق أصفر خاص بالتصوير.

يعتبر الورق الأصفر الخاص بالتصوير وسيط لنقل المسارات إلى طبقة النحاس في الدارة التي نريد تصنيعها، حيث تنتقل المسارات من الورق إلى طبقة النحاس من خلال الحرارة.

الشكل(21-4) الأدوات المستخدمة في نقل الحبر من الورق إلى طبقة النحاس.

تم قص الورق الأصفر بأبعاد تطابق أبعاد لوح النحاس، وتم مطابقة حدود الورق مع حدود اللوح وتعريض الورق الأصفر لحرارة عالية لمدة 3 إلى 5 دقائق من خلال مكواة منزلية، مع العلم أن تعريض اللوح إلى حرارة عالية لفترة طويلة قد يسبب انفصال طبقة النحاس عن طبقة فايبر الدارة (لوح النحاس هو عبارة عن طبقة من النحاس رقيقة وطبقة سميكة من الفايبر)، ولتحسين عملية نقل الحبر من الورق إلى اللوح تم سكب الماء البارد على اللوح بحيث يتعرض لـ "صدمة حرارية" تساعد في نقل جميع المسارات دون انقطاع وتقلل من الزمن اللازم لعملية النقل. نلاحظ في الشكل أعلاه انتقال الحبر بشكل سليم بعد الصدمة الحرارية.

الشكل(22-4) تحميض الدارة باستخدام مادة كلوريد الحديديك.

بعد أن تمت عملية نقل الحبر بشكل صحيح إلى اللوح النحاسي دون وجود أي مسارات مقطوعة – مع العلم أنه يمكن تصحيح هذه المسارات من خلال استخدام أقلام دهان خاصة يمكن رسم المسارات المقطوعة يدوياً – يتم تحميض الدارة باستخدام مادة كلوريد الحديديك $FeCl_3$، حيث يكون الحمض بشكل مادة صلبة يتم حله مع الماء ضمن وعاء بلاستيك سميك تجنباً لتآكل البلاستيك من قبل الحمض حيث يتم حل 200 ميليمتر تقريباً من الماء مع كيس كامل من المحلول لسرعة تفاعل أكبر. يتم وضع اللوح النحاسي ضمن وعاء الحمض ويتم تحريك الوعاء لمدة 20 دقيقة لتفاعل أسرع، وبعد انتهاء المدة يكون الحمض قد تفاعل مع كامل سطح النحاس وأذابه إلا مع المسارات المغطاة بالحبر وبالتالي تمكنا من رسم المسارات من خلال إذابة المساحات التي لا نحتاجها.

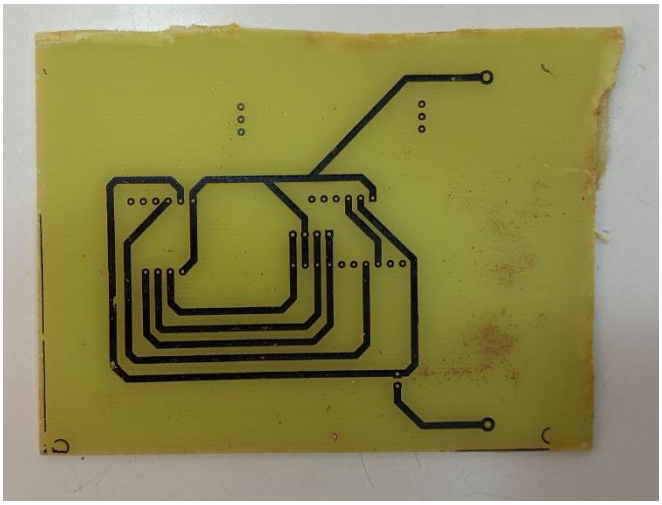

الشكل(23-4) شكل الدارة من الأسفل بعد انتهاء مدة التحميض. (نلاحظ أن المساحة الصفراء تمثل مادة الفايبر وخطوط الحبر تحتها مسارات الدارة النحاسية).

بعد انتهاء فترة التحميض يتم شحذ اللوح بورق الصنفرة Sandpaper (ورق الزجاج أو السمبادج) الناعم لإزالة الحبر عن المسارات المتبقية، مع أخذ الاحتياط أثناء عملية الشحذ تجنباً لنزع المسارات النحاسية.

الشكل(24-4) لوح النحاس بعد شحذه (نلاحظ المسارات النحاسية المتبقية من عملية التحميض).

يتم تثقيب الدارة بثقوب لمرور دبابيس العناصر من خلالها، وذلك لأن نوع العناصر المستخدمة في الدارة هي Through Hole TH وهي عناصر يكون جسم العنصر في طبقة الـ Top ويكون اللحام في طبقة الـ Bottom. يتم التثقيب برؤوس أقطار 0.8 و1 و1.5 ميليمتر بناءً على طبيعة غلاف Package كل

عنصر وعرض كل Pin. تم شحذ وقص حواف الدارة النهائية بعد تثقيبها ولحم العناصر عليها، وكانت النتيجة النهائية للدارة كاملة كما في الصورة .

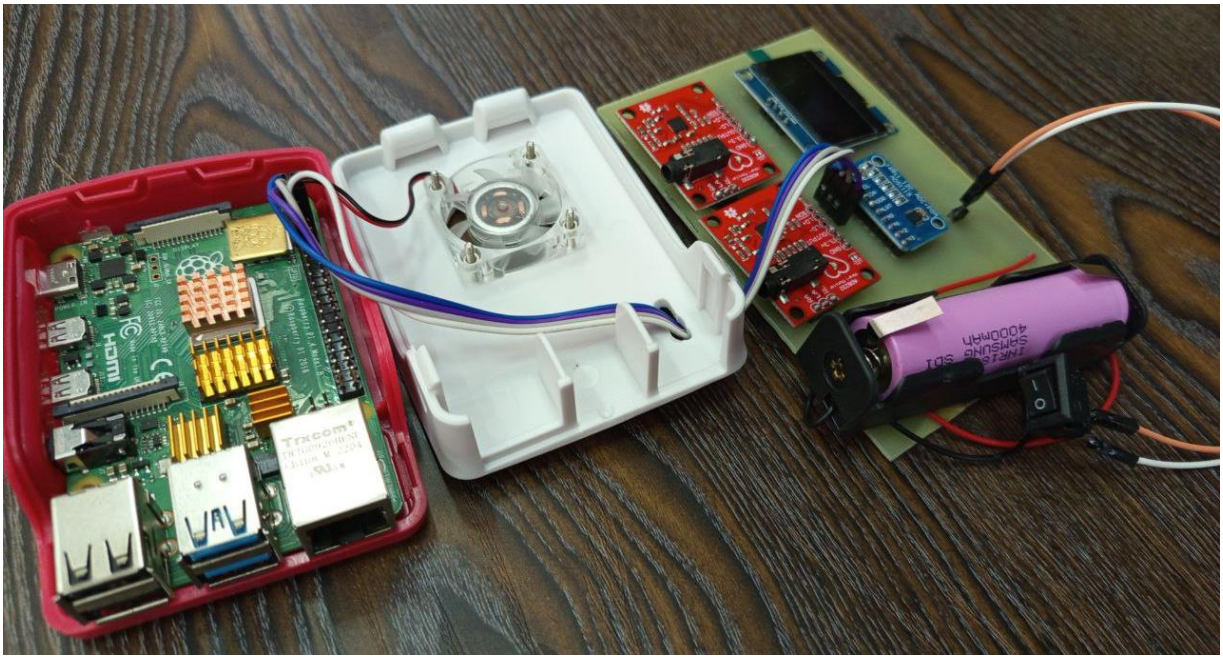

الشكل(25-4) الشكل النهائي لدارة الاقتباس يظهر فيها لوحة Raspberry Pi ودارة الاقتباس.

ومن أجل الغلاف الخارجي للجهاز تم تصميمه وتصنيعه من خلال ألواح الأكريليك Acrylic Sheets أو ما يسمى تجارياً ألواح البلكسي. بلغ حجم الجهاز كاملاً بعد التجميع 15×12 سم مع سماكة 5 سم.

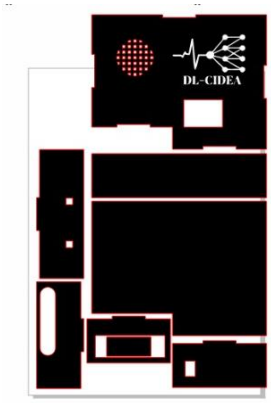

الشكل(26-4) قطع علبة ألواح البلكسي.

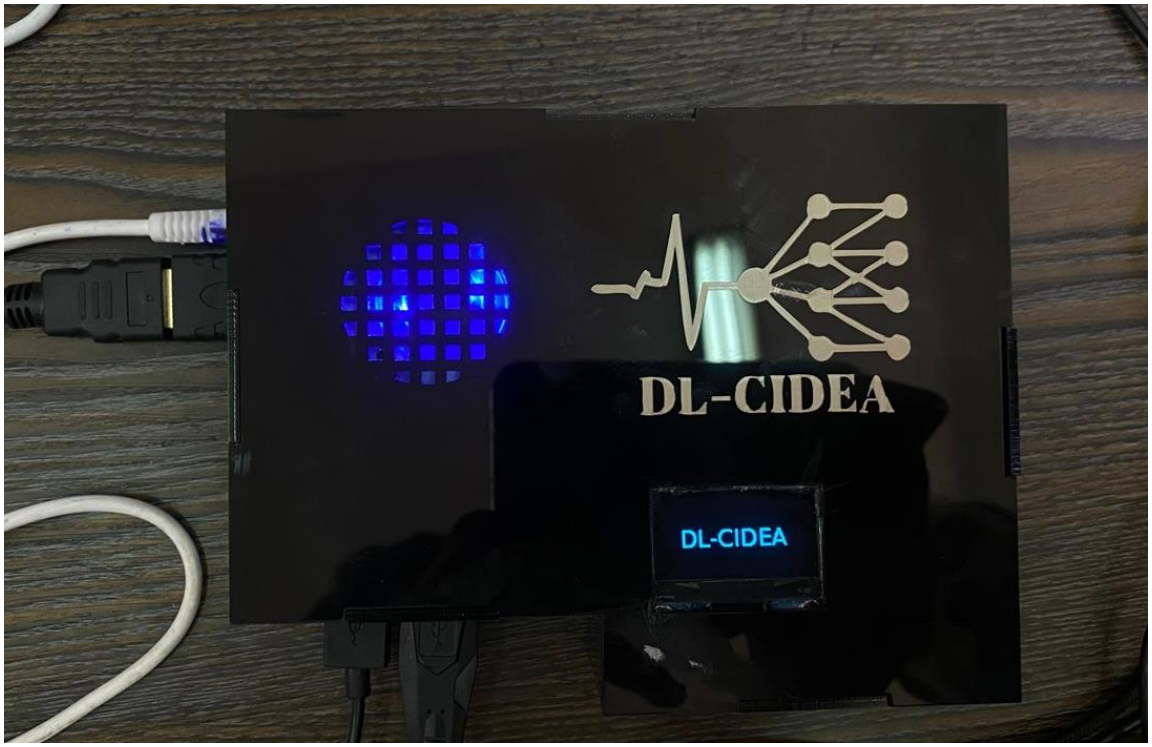

الشكل(27-4) الشكل النهائي للجهاز مع شعار المشروع DL-CIDEA.

4.4 الجانب البرمجي:

في هذا الجانب تم العمل على مستويين، مستوى الربط بين دارة الاقتباس ونموذج التعلم العميق، ومستوى المعاجلة الأولية للبيانات من خلال ترشيحها Filtering وكشف قمم الموجة R/ R-Peaks Detector، وتقطيع تسجيلات مخطط القلب الكهربائي Slicing. تم كتابة الأكواد من خلال لغة بايثون Python وهي لغة برمجية عالية المستوى، مفسرة، متعددة الاستخدامات وهي الرائدة في مجال تحليل البيانات الذكاء الصنعي والتعلم الآلي. سيتم شرح الأدوات المستخدمة في كتابة الأكواد ثم بعدها نتناول موضوع المعالجة الأولية للبيانات.

1.4.4 برنامج Visual Studio Code - VS Code:

أحد أشهر بيئات التطوير البرمجية الحديثة Source Code Editor التي طورتها شركة Microsoft، وهو برنامج مفتوح المصدر ومجاني، يتميز بحجمه الخفيف وسهولة تخصيصه مقارنةً بالبيئات البرمجية التقليدية، يُستخدم VS Code على نطاق واسع في الأوساط الأكاديمية والصناعية لتطوير البرمجيات، تطبيقات الويب، الذكاء الصنعي، ومعالجة البيانات.

يدعم VS Code عدداً كبيراً من لغات البرمجة مثل Python و C/C++ و Java و JavaScript و HTML/CSS، يتميز بدمجٍ مباشر مع أنظمة التحكم بالإصدارات مثل Git وGitHub، مما يسهّل إدارة المستودعات البرمجية والتعاون بين أعضاء الفرق البحثية، إلى جانب ذلك يوفر البرنامج إمكانية تخصيص واسعة النطاق من خلال سوق الإضافات Extensions Marketplace، حيث يمكن للمستخدم إضافة أدوات الذكاء الصنعي، أو المصححات البرمجية، أو المكتبات العلمية تبعاً لاحتياجاته.

الشكل(28-4) شعار برنامج VS Code.

باستخدام برنامج VS Code تم كتابة الأكواد الخاصة بعملية كشف قمم الموجة R، حيث يعتمد هذا الكود في عمله على خوارزمية تدعى Pan-Tompkins وهي من أشهر الخوارزميات لاكتشاف قمم الموجة R، حيث تعمل الخوارزمية في عدة مراحل متسلسلة وهي أولاً الترشيح Filtering حيث تهدف إلى إزالة ضوضاء العضلات وضوضاء الشبكة الكهربائية 50/60 Hz وضوضاء انحدار خط الأساس Baseline Wander، تعمل مرحلة الترشيح كمرحلة مرشح تمرير نطاق بتردد تقريبي 5-15Hz حيث يعزز هذا الأمر من QRS ويضعف باقي الإشارات، ثم بعدها التفاضل Differentiation حيث يتم اشتقاق الإشارة القلبية حتى يتم التركيز أكثر على التغيرات اللحظية، ثم تربع الإشارة المشتقة من خلال تابع التربيع Square Function مما يجعل جميع قيم الإشارة موجبة وتضخم الإشارة بشكل أكبر، ثم يتم إجراء تكامل متحرك Moving Window Integration بحيث يتم أخذ متوسط على نافذة زمنية بين 200 ميلي ثانية و 150 ميلي ثانية حيث تحاكي النافذة عرض النبضة القلبية، والهدف من هذه الخطوة هو توحيد شكل الإشارة بحيث تصبح QRS سهلة التحديد، وأخيراً يتم كشف العتبة Thresholding & Decision بحيث يتطبق عتبات ديناميكية Adaptive Thresholds لاكتشاف القمم بحيث إذا تجاوزت القمة قيمة معينة مع شرط

زمني مناسب يتم تصنيفها كقمة R، ويجب التنويه أنه وبشكل تلقائي يتم تعديل قيمة العتبة حسب تغير الإشارة الأمر الذي يميز الخوارزمية بحيث تعمل في ظروف مختلفة.

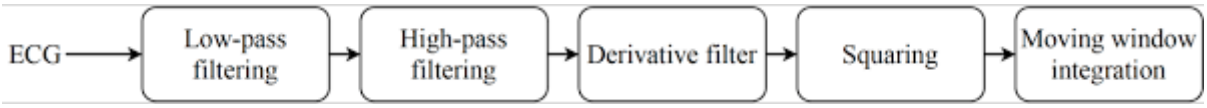

الشكل(29-4) مخطط صندوقي يوضح آلية عمل خوارزمية Pan-Tompkins.

بعد مرحلة كشف قمم الموجة R، أصبح بالإمكان تقطيع التخطيط القلبي إلى نبضات بناءً على موقع Index كل قمة، حيث يتم اقتطاع نافذة حول موقع القمة R، هذ الأمر يجعل النبضة القلبية بطول زمني [pre-window, post-window]، يتم اختيار عرض الاقتطاع اعتماداً على تردد العينات Frequency Sampling، ففي حال افترضنا أن عرض النبضة كاملاً هو 600ms وعلى فرض أن:

$$Pre - Window = fs * 0.2$$

$$Post - Window = fs * 0.4$$

ففي حال كانت قيمة تردد العينات يساوي 360 هرتز، فبالتالي تكون القيم:

$$Pre - Window = 360 * 0.2 = 72$$

$$Post - Window = 360 * 0.4 = 144$$

وبالتالي يكون الطول الكلي للنبضة هو مجموع القيمتين وبالتالي يكون طول النبضة يساوي 216 عينة. أثناء عملية التقطيع يتم الاحتفاظ بشرح كل نبضة.

إن قواعد البيانات الطبية لها خصوصية عن مختلف قواعد البيانات الأخرى، حيث أن الحجم الهائل للبيانات التي يمكن تسجيلها من خلال الحساسات الحيوية دعا المجتمع البرمجي إلى توفير أنواع جديدة

لتخزين وشرح وحفظ هذه البيانات بمساحة تخزينية أقل وجودة أعلى ومعلومات أكثر. إن مختلف قواعد البيانات الطبية تعتمد في تخزينها على الملفات من النوع (.hea, .atr, .dat)، إن كل ملف من الملفات السابقة يحوي معلومات خاصة بالإشارة الحيوية، فبالنسبة للملفات ذات اللاحقة hea. فهي تعرف على أنها ملفات الترويسة (أو الرأسية) Header files وهي ملفات نصية تصف خصائص التسجيل، فيمكن أن نجد ضمن هذه الملفات معلومات حول: عدد القنوات المستخدمة ونوعها، تردد العينات، طول التسجيل القلبي، ومعلومات ديموغرافية أخرى مثل العمر، الجنس، التشخيص السريري، تاريخ التسجيل وتوقيته، اسم الشريان المصاب (خاصة بقواعد البيانات القلبية). أما بالنسبة للبيانات من نوع dat. فهي تحتوي على القيم الرقمية الخام للإشارة القلبية، تتميز هذه الملفات بحجمها الصغير وسرعتها في القراءة، وبالتالي هي مناسبة لتكون ملفات تخزينية لتسجيلات قلبية طويلة، ونلاحظ هذا الأمر مثلاً في قاعدة البيانات Long Term ST Database حيث أنها تحتوي على قراءات قلبية لتسجيلات تتراوح مدتها بين 21 وحتى 24 ساعة، وبالتالي بعملية حسابية صغيرة يمكن معرفة أن تسجيل واحد مدته 21 ساعة من قاعدة البيانات السابقة يحتوي على 18.9 مليون عينة، مما يتطلب وحدة تخزين أكبر وبالتالي كانت الملفات من نوع dat. حل لمشكلة المساحة التخزينية. أما بالنسبة للملفات من نوع atr. فهي بمثابة تعليقات أو وسوم Labels مرتبطة بالتسجيل، يتم فيها تخزين مواقع قمم R، ونوع كل نبضة، وهي ملفات مهمة في عملية التصنيف من أجل تنظيم عنونة البيانات.

تم الاعتماد ضمن المشروع على قاعدة البيانات European ST – T Database V1.0.0 حيث تم شرح مواصفات هذه القاعدة في الدراسة المرجعية الثالثة. تم تنفيذ الأكواد التي ذكرها سابقاً وتم الحصول على حوالي 1557 نبضة تعبر عن الإقفار القلبي، وتم الحصول على 385,000 نبضة سليمة، تم تشكيل قاعدة بيانات متوازنة حتى لا يحدث حالة انحياز أثناء تدريب نموذج التعلم العميق. وتم تدريب النموذج عليها.

2.4.4 منصة Google Colab:

يُعد Google Colab منصة حوسبة سحابية مجانية طورتها شركة Google، وهو امتداد لمكتبة Jupyter Notebook، تتميز هذه المنصة بأنها تتيح للمستخدمين كتابة وتنفيذ الأكواد البرمجية مباشرة عبر المتصفح، دون الحاجة إلى إعداد بيئات برمجية محلية أو تثبيت مكتبات، حيث توفر بيئة جاهزة تعتمد على لغة Python مع دعم واسع للمكتبات العلمية مثل NumPy و Pandas و TensorFlow و PyTorch.

أحد أبرز مميزات Google Colab هو إتاحته موارد حوسبية قوية، مثل وحدات المعالجة الرسومية Graphical Processor Unit GPU ووحدات المعالجة المخصصة للتعلم العميق Tensor Processor Unit TPU، بشكل مجاني أو شبه مجاني، مما يجعله أداة مناسبة لتدريب النماذج العميقة ومعالجة البيانات الضخمة، وإلى جانب ذلك يتيح تخزين الملفات ونتائج التجارب بشكل مباشر عبر Google Drive، ما يسهل مشاركة المشاريع والتعاون بين الفرق البحثية والطلاب، ويجعل الوصول إلى البيانات والنماذج متاحاً من أي مكان وفي أي وقت. وبفضل كونه منصة قائمة على السحابة، فإن Google Colab يخفف من القيود المرتبطة بالعتاد الشخصي، إذ لا يحتاج المستخدم إلى جهاز بمواصفات عالية لتشغيل الخوارزميات المعقدة، بل يعتمد على موارد حوسبية تقدمها Google، ويضاف إلى ذلك مجتمع دعم واسع عبر الإنترنت، يوفر أمثلة جاهزة وبرمجيات تفاعلية من نوع Notebooks قابلة للمشاركة والتعديل وكتابة الكتل البرمجية المنفصلة، وبذلك يُمثل Google Colab أداة قوية تجمع بين سهولة الاستخدام والمرونة العالية والإمكانات الحوسبية الكبيرة.

الشكل(30-4) شعار منصة Google Colab.

تم استخدام منصة Google Colab في مرحلة تدريب نموذج التعلم العميق، حيث تم الاستفادة من الخدمات المجانية التي تقدمها المنصة بالإضافة إلى الميزات والأداء العالي بحيث يمكن الاستفادة من هذه الميزات وتدريب النماذج ذات التكلفة الحاسوبية العالية سحابياً. سيتم كتابة كل من كود التقطيع وكود كشف القمم وكود النموذج ضمن الملحق.

الفصل الخامس

النتائج والمناقشة

Conclusions and Discussion

5 الفصل الخامس

النتائج والمناقشة

Conclusions and Discussion

1.5 مقدمة:

يقدم هذا الفصل مجموعة النتائج التي توصلنا إليها بعد البحث والعمل على ربط دارة الاقتباس بنموذج التعلم العميق المدرب مسبقاً من خلال لوحة Raspberry Pi، وتجريب هذا النظام المتكامل على مجموعة محلية صغيرة من فئة الشباب.

2.5 النتائج والمناقشة:

بعد هذا البحث توصلنا إلى نتائج جيدة في الحصول على إشارة جيدة مقتبسة من خلال دارة الاقتباس، كما أن الموديل أبدى نتائج جيدة على مجموعة البيانات المدربة على الرغم من قلة البيانات المريضة. ولكن يجدر الإشارة إلى اننا نتوقع نتائج أفضل ذات دقة أكبر في حال تم تأمين قاعدة بيانات محلية تعبر عن طبيعة إشارات المرضى المحلية. وفي نهاية الأمر نرى أنه يمكن مناقشة تنفيذ الجهاز على أرض الواقع وادراجه ضمن المشافي الحكومية الأمر الذي يقلل عبأ على الطبيب ويوفر بضعة دقائق تكاد تكون مصيرية في حياة المريض.

3.5 المشاكل التي واجهتنا:

واجه المشروع خلال مراحله التنفيذية عدداً من الصعوبات التقنية والعملية التي تطلّبت حلولاً مبتكرة للتغلب عليها، وفيما يلي شرح لمختلف المشاكل من نواحي عدة:

1.3.5 على الصعيد الطبي:

إن من أهم المشاكل في هذا الصعيد هو ضعف الإلمام المعرفي بالجانب الطبي الخاص بمرض الإقفار القلبي، حيث أن طبيعة النبضات الإقفارية لها عدة أشكال وهذه الأشكال لا تحسم الأمر في ما إذا كان المريض مصاباً أم لا بالإقفار القلبي، إذ أن النبضات الإقفارية قد تظهر في مخطط ECG نتيجة عوامل أخرى لا علاقة لها بالمرض نفسه، فمن الممكن أن تناول بعض الأدوية بشكل خاطئ أو الإصابة بالتهاب

غشاء التامور أو تضخم البطين الأيسر قد يكون سبباً في ظهور هذه النبضات مما يؤدي إلى توجه خاطئ في التشخيص، الأمر الذي جعل من الصعب حصر العوامل التي تساهم في تشخيص الإقفار القلبي.

2.3.5 على صعيد العتاد المادي:

كان من أبرز هذه التحديات اقتباس إشارة القلب بجودة عالية نظراً لصغر قيمتها ووجود ضجيج مرتفع يؤثر عليها، مما استدعى عناية خاصة في تصميم الدارة والاعتماد على تقنيات ترشيح ومعايرة مناسبة، كما ظهرت مشكلة في عمل حساس القلب، وقد جرى تجاوزها عبر توصيل بطارية خارجية وفّرت أرضياً مستقراً Common Ground ساهم في تقليل التشويش بشكل ملحوظ.

وفيما يتعلق بالجانب التحكمي، واجهنا تحديات متعددة في تشغيل منصة Raspberry Pi، بدءاً من تحميل نظام التشغيل وحتى ضمان توافق النسخة مع العتاد المُسْتَخْدَم، حيث أدى الاعتماد على إصدار قديم من النظام إلى مشكلات في التوافق، مما فرضَ تحديث النظام إلى نسخة أحدث، كما أن عدم دعم Raspberry Pi للمدخلات التماثلية ألزمنا على استخدام محول تماثلي رقمي ADC لاقتباس الإشارات الحيوية. ومن الصعوبات الأخرى ارتفاع تكلفة نسخة Raspberry Pi 4 مقارنة ببدائل محدودة في السوق، إضافةً إلى محدودية سعة الذاكرة العشوائية RAM التي قيدت إمكانية تشغيل أكثر من عملية بشكل متزامن. كما واجهنا مشكلة في توفير مزوّد طاقة مناسب، إذ إن دارة Raspberry pi 4B لا تعمل إلا عند توفر مصدر تغذية يوفر القدرة المطلوبة على الأقل 15 واط كحد أدنى وكلما كان مصدر التغذية ذو استطاعة أكبر عمل معالج Raspberry Pi بشكل أفضل، وتم تأمين مصدر التغذية من خلال شاحن هاتف 33 واط. أما من الناحية الحرارية، فقد لوحظت مشكلة ارتفاع درجة حرارة دارة Raspberry Pi أثناء التشغيل، الأمر الذي فرض استخدام مشتتات حرارية Heat Sinks ومروحة تبريد صغيرة لتفادي أي أعطال أو تراجع في أداء اللوحة. وأخيراً شكّل نقص المصادر التعليمية باللغة العربية حول برمجة Raspberry Pi عائقاً إضافياً، حيث تطلب ذلك الرجوع إلى مصادر أجنبية ودروس تقنية متقدمة، مما زاد من صعوبة مرحلة التعلم والتطبيق.

3.3.5 على صعيد قواعد البيانات:

تمثلت التحديات التي واجهتنا على صعيد قواعد البيانات في عدة أشكال، بدءاً من خصوصية الملفات المستخدمة في قواعد البيانات الطبية الخاصة، حيث لم يتم التعرف في المراحل الأولى على كيفية التعامل مع الملفات بالصيغ (.atr - .hea - .dat) ما أدى إلى إعاقة تقدم المشروع وعدم إمكانية قراءة تسجيلات القلب الكهربائية، ومن ناحية أخرى فقواعد البيانات المتوافرة على موقع PhysioNet.org كان لكل منها خصائصها وميزاتها وعيوبها، فكانت أحد أكبر المشاكل هو عدم توافر قواعد بيانات بنبضات مشروحة Annotated Beats بل كانت معنونة (مُشَخصة) على صعيد التسجيل Labeled ECG Record الأمر الذي أدى إلى إزالة بعض من قواعد البيانات التي لا تصلح في بحثنا.

كما أن عدم توافر قواعد بيانات محلية يجعل من تدريب نموذج التعلم العميق غير موجه نحو فئة بلد المنشأ، الأمر الذي يقلل من دقة أداء النموذج في عملية التصنيف بسبب الاختلاف بين طبيعة الإشارة القلبية لقواعد البيانات المدرب عليها (قواعد غير محلية) وبين طبيعة الإشارة القلبية للفئة المستهدفة (قواعد محلية).

كما أن الحجم الهائل لبعض قواعد البيانات مثل Long Term ST Database v1.0.0 والذي يبلغ حوالي 9.5 غيغابايت جعل من الصعب معالجتها أولياً بشكل محلي على أجهزة الحاسوب الشخصية، ما أدى إلى استبعاد قاعدة بيانات تحوي معلومات مفيدة لتطبيقنا.

الفصل السادس

الآفاق المستقبلية

Future Work

6 الفصل السادس

الآفاق المستقبلية

Future Work

1.6 على الصعيد البرمجي:

1.1.6 تطوير خوارزمية التعلم العميق:

تحسين الخوارزمية المستخدمة في المشروع لزيادة دقة تصنيف الإشارات القلبية وتقليل الأخطاء، يشمل ذلك تعديل بنية الشبكة العصبية، ضبط المتغيرات Hyperparameters ، واستخدام تقنيات مثل التحقق المتقاطع Cross-Validation لمنع الإفراط في التعلم Overfitting، مما يعزز موثوقية النتائج على عينات جديدة من البيانات، وإضافة أمكانية الكشف عن أكثر من مرض

2.1.6 بناء قواعد بيانات محلية:

استخدام قواعد بيانات محلية تحتوي على تسجيلات ECG عالية الجودة، لتتناسب مع الخصائص الفيزيولوجية والسريرية للبيئة المستهدفة، هذا يضمن توافق النتائج مع السمات الفيزيولوجية الخاصة بالمرضى المحليين ويزيد من دقة التشخيص والتطبيق العملي للجهاز ضمن الإطار المحلي.

2.6 من ناحية العتاد المادي:

1.2.6 دمج شاشة لمس تفاعلية:

إدراج شاشة TFT تمكن المستخدم من عرض الإشارة القلبية بشكل لحظي، واستعراض نتائج القياس مما يجعل التعامل مع النظام أكثر سهولة ويتيح متابعة لحظية للحالة الصحية.

2.2.6 توسيع النظام ليشمل حساسات إضافية:

إضافة مجسّات لقياس ضغط الدم، تشبع الأكسجين، لتكوين منظومة رصد متعددة الإشارات. هذا التوسيع يسمح بالحصول على صورة شاملة للحالة الصحية، ويساهم في تحقيق تشخيص طبي شبه متكامل دون الحاجة لتجهيزات إضافية منفصلة.

3.2.6 تقليل عدد الأقطاب المستخدمة:

اعتماد ثلاثة أقطاب فقط بدلاً من العدد المستخدم وهو 6 أقطاب، لتسهيل وضعها على المريض وزيادة راحته، ما يعزز تقبّل المرضى للجهاز ويجعل استخدامه أكثر عملية في البيئات السريرية والتعليمية.

4.2.6 تحسين جودة الإشارة:

إدخال فلاتر إلكترونية متقدمة وتصميم دارة اقتباس خاصة لتقليل التشويش والضجيج الناتج عن حركة العضلات أو التداخل الكهربائي، مما يحسن وضوح الموجة القلبية ويزيد دقة القياسات.

5.2.6 تحويل الجهاز إلى نظام مراقبة ذكي مستمر:

إمكانية تحويل الجهاز إلى أداة مراقبة دائمة للحالة الصحية من خلال ربطه بشبكات الرعاية الصحية، وإنشاء تطبيق أو موقع إلكتروني لتخزين البيانات وإتاحتها للطبيب بشكل لحظي. هذا يتيح متابعة مستمرة للحالة الصحية والتدخل المبكر عند حدوث أي تغييرات طارئة، مما يعزز فعالية التشخيص والعلاج ويحسن جودة الرعاية الصحية.

الملحق

Supplement

7 المحلق
Supplement

1.7 كود كشف قمة الموجة R /R-Peaks Detectors مع كود تقطيع البيانات Beats Slicer:

```
import os
import numpy as np
import wfdb
import pandas as pd
from scipy.signal import butter, filtfilt
# -------- Parameters --------
TARGET_LEADS = ["MLIII", "MLII", "D3", "D2", "III", "II", "AVF"]
ANNOT_FILTER = ["s", "T", "N"]
OUTPUT_FOLDER = "IncartBeats"
WINDOW = (-0.2, 0.6)  # seconds before and after R peak
# -------- Pan–Tompkins Implementation --------
def bandpass_filter(signal, fs, lowcut=0.5, highcut=50, order=1):
    nyq = 0.5 * fs
    low = lowcut / nyq
    high = highcut / nyq
    b, a = butter(order, [low, high], btype="band")
    return filtfilt(b, a, signal)
def derivative(signal, fs):
    return np.gradient(signal)
def moving_window_integration(signal, window_size):
    window = np.ones(window_size) / window_size
```

```
    return np.convolve(signal, window, mode="same")
def pan_tompkins_detect(signal, fs):
    # Bandpass filter
    filtered = bandpass_filter(signal, fs)
    # Differentiate
    diff = derivative(filtered, fs)
    # Square
    squared = diff**2
    # Moving window integration (~150 ms window)
    window_size = int(0.15 * fs)
    integrated = moving_window_integration(squared, window_size)
    # Thresholding
    threshold = np.mean(integrated) * 1.2
    r_peaks = np.where(integrated > threshold)[0]
    # Refine: keep local maxima only
    refined = []
    refractory = int(0.2 * fs)  # 200 ms
    last_peak = -refractory
    for idx in r_peaks:
        if idx - last_peak > refractory:
            window = signal[max(0, idx - 10): idx + 10]
            if len(window) > 0:
                peak = idx - 10 + np.argmax(window)
                refined.append(peak)
                last_peak = peak
    return np.array(refined)
# -------- Utilities --------
def get_lead_indices(record, target_leads):
```

```
    """Find indices of target leads in WFDB record (case-insensitive)."""
    lead_indices = {}
    for i, name in enumerate(record.sig_name):
        for target in target_leads:
            if name.lower() == target.lower():
                lead_indices[target.upper()] = i
    return lead_indices
def slice_beat(signal, r_idx, fs, window=WINDOW):
    """Slice one beat around R-peak with a time axis."""
    start = int(r_idx + window[0] * fs)
    end = int(r_idx + window[1] * fs)
    if start < 0 or end > len(signal):
        return None, None
    beat = signal[start:end]
    time = np.linspace(window[0], window[1], len(beat))
    return time, beat
def process_record(folder, record_name, out_folder=OUTPUT_FOLDER,
window=WINDOW):
    """Process one ECG record: detect R-peaks, slice beats, save CSVs."""
    # ---- Load record ----
    record = wfdb.rdrecord(os.path.join(folder, record_name))
    fs = record.fs
    # ---- Detect R-peaks (Pan–Tompkins) ----
    sig0 = record.p_signal[:, 0]  # first channel for detection
    r_peaks = pan_tompkins_detect(sig0, fs)
    # ---- Load annotations ----
    ann = wfdb.rdann(os.path.join(folder, record_name), "atr")
    ann_samples = ann.sample
    ann_symbols = ann.symbol
```

```
    # ---- Map leads ----
    lead_indices = get_lead_indices(record, TARGET_LEADS)
    if not lead_indices:
        print(f"⚠ No target leads found in {record_name}")
        return
    # ---- Match annotations to R-peaks ----
    for i, (s, sym) in enumerate(zip(ann_samples, ann_symbols)):
        if sym not in ANNOT_FILTER:
            continue
        # Find nearest detected R-peak
        if len(r_peaks) == 0:
            continue
        r_idx = min(r_peaks, key=lambda r: abs(r - s))
        for lead, idx in lead_indices.items():
            sig = record.p_signal[:, idx]
            t, beat = slice_beat(sig, r_idx, fs, window)
            if beat is None:
                continue
            # ---- Save CSV ----
            lead_folder = os.path.join(out_folder, lead)
            os.makedirs(lead_folder, exist_ok=True)
            filename = f"{record_name}_beat{i:03d}_{sym}.csv"
            filepath = os.path.join(lead_folder, filename)
            df = pd.DataFrame({"time (s)": t, f"{lead} (mV)": beat})
            df.to_csv(filepath, index=False)
def process_folder(folder, max_records=None):
    """Process multiple records from a folder."""
    records = [f[:-4] for f in os.listdir(folder) if f.endswith(".hea")]
```

```
    records = sorted(records)
    if max_records:
        records = records[:max_records]
    for rec in records:
        print(f"\n▶ Processing {rec}...")
        process_record(folder, rec)
    print("\n✅ Done!")
# -------- Example usage --------
if __name__ == "__main__":
    folder = r""  # change to your dataset path
    process_folder(folder, max_records=)  # process first N records
```

2.7 كود نموذج التعلم العميق:

```
import tensorflow as tf
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Conv1D, MaxPooling1D, Flatten, Dense, Dropout,
BatchNormalization, LeakyReLU
import os
fixed_len = 200
num_classes = 3
model = Sequential([
    Conv1D(200, 7, input_shape=(fixed_len,1)),
    LeakyReLU(alpha=0.1),
    BatchNormalization(),
    MaxPooling1D(2),
    Conv1D(128, 5),
    LeakyReLU(alpha=0.1),
    BatchNormalization(),
    MaxPooling1D(2),
```

```
    Conv1D(64, 5),
    LeakyReLU(alpha=0.1),
    BatchNormalization(),
    MaxPooling1D(2),
    Flatten(),
    Dense(64),
    LeakyReLU(alpha=0.1),
    Dropout(0.5),
    Dense(num_classes, activation='softmax')
])
model.compile(optimizer='adam', loss='sparse_categorical_crossentropy',
metrics=['accuracy'])
save_dir = r"C:\Users\Mohammed\Desktop\DL-CIDEA_model\SavedModels"
os.makedirs(save_dir, exist_ok=True)
h5_path = os.path.join(save_dir, "ecg_cnn_full_model.h5")
model.save(h5_path)
model_loaded = tf.keras.models.load_model(h5_path)
converter = tf.lite.TFLiteConverter.from_keras_model(model_loaded)
converter.target_spec.supported_ops = [
    tf.lite.OpsSet.TFLITE_BUILTINS,
    tf.lite.OpsSet.SELECT_TF_OPS
]
tflite_model = converter.convert()
tflite_path = os.path.join(save_dir, "ecg_cnn_model.tflite")
with open(tflite_path, "wb") as f:
    f.write(tflite_model)
```

3.7 كود Raspberry Pi:

```
import sys
import numpy as np
import tflite_runtime.interpreter as tflite
import board, busio
import adafruit_ads1x15.ads1115 as ADS
from adafruit_ads1x15.analog_in import AnalogIn
from pyqtgraph.Qt import QtWidgets, QtCore
import pyqtgraph as pg
from luma.core.interface.serial import i2c
from luma.oled.device import sh1106
from PIL import Image, ImageDraw, ImageFont
interpreter = tflite.Interpreter)
    model_path="/home/mohammed/Desktop/ecg_cnn_model.tflite"
(
interpreter.allocate_tensors()
input_details = interpreter.get_input_details()
output_details = interpreter.get_output_details()
classes = ["Normal", "Ischemia", "Undiagnosed"]
window_size = 200
threshold = 0.6
serial = i2c(port=1, address=0x3C)
device = sh1106(serial, width=128, height=64)
font = ImageFont.truetype("/usr/share/fonts/truetype/dejavu/DejaVuSans.ttf", 14)
def show_on_oled(lines):
```

```
    image = Image.new("1", (device.width, device.height), 0)
    draw = ImageDraw.Draw(image)
    y = 0
    for line in lines:
        draw.text((0, y), line, font=font, fill=255)
        y += 20
    device.display(image)
i2c_ads = busio.I2C(board.SCL, board.SDA)
ads = ADS.ADS1115(i2c_ads)
leadII_channel = AnalogIn(ads, ADS.P0)
leadIII_channel = AnalogIn(ads, ADS.P1)
app = QtWidgets.QApplication(sys.argv)
win = pg.GraphicsLayoutWidget(title="ECG Leads")
win.show()
win.resize(800 ,1000)
plot1 = win.addPlot(title="Lead II")
curve_leadII = plot1.plot(pen="g")
win.nextRow()
plot2 = win.addPlot(title="Lead III")
curve_leadIII = plot2.plot(pen="b")
win.nextRow()
plot3 = win.addPlot(title="aVF (Computed)")
curve_avf = plot3.plot(pen="r")
fs = 250
max_points = 500
time_data = np.linspace(-max_points / fs, 0, max_points)
```

```
data_leadII = np.zeros(max_points)
data_leadIII = np.zeros(max_points)
data_avf = np.zeros(max_points)
buffer_leadII, buffer_leadIII, buffer_avf[] ,[] ,[] =
counters} =
"     Lead II": {"Normal": 0, "Ischemia": 0, "Undiagnosed": 0},
"     Lead III": {"Normal": 0, "Ischemia": 0, "Undiagnosed": 0},
"     aVF": {"Normal": 0, "Ischemia": 0, "Undiagnosed": 0},
{
def update:()
    global data_leadII, data_leadIII, data_avf
    vII = leadII_channel.voltage
    vIII = leadIII_channel.voltage
    vAVF = (vII + vIII) / 2
    data_leadII = np.roll(data_leadII, -1)
    data_leadII[-1] = vII
    data_leadIII = np.roll(data_leadIII, -1)
    data_leadIII[-1] = vIII
    data_avf = np.roll(data_avf, -1)
    data_avf[-1] = vAVF
    curve_leadII.setData(time_data, data_leadII)
    curve_leadIII.setData(time_data, data_leadIII)
    curve_avf.setData(time_data, data_avf)
    buffer_leadII.append(vII)
    buffer_leadIII.append(vIII)
```

```
    buffer_avf.append(vAVF)
    if len(buffer_leadII) >= window_size:
        for lead_name, buffer in zip)
            ["Lead II", "Lead III", "aVF"], [buffer_leadII, buffer_leadIII, buffer_avf]
:(
            segment = np.array(buffer[-window_size:])
            segment = (segment - np.mean(segment)) / (np.std(segment) + 1e-8)
            data = np.array(segment, dtype=input_details[0]["dtype"]).reshape)
                input_details[0]["shape"]
(
            interpreter.set_tensor(input_details[0]["index"], data)
            interpreter.invoke()
            output_data = interpreter.get_tensor(output_details[0]["index"])[0]
            max_prob_index = np.argmax(output_data)
            max_prob = output_data[max_prob_index]
            if max_prob >= threshold:
                result = classes[max_prob_index]
            else:
                result = "Undiagnosed"
            counters[lead_name][result] += 1
        print("📊 Counters:")
        for lead, counts in counters.items:()
            print(f"{lead}: {counts}")
```

```
        c = counters["Lead II"]
        lines] =
            f"Normal: {c['Normal']},"
            f"Ischemia: {c['Ischemia']},"
            f"Undiag: {c['Undiagnosed']},"
[
        show_on_oled(lines)


timer = QtCore.QTimer()
timer.timeout.connect(update)
timer.start(int(1000 / fs))
sys.exit(app.exec_())
```

المراجع

References

المراجع

References

[1] Pyakillya, B., Kazachenko, N., & Mikhailovsky, N. (2017, October). Deep learning for ECG classification. In Journal of physics: conference series (Vol. 913, No. 1, p. 012004). IOP Publishing.

[2] Bigler, M. R., & Seiler, C. (2021). Detection of myocardial ischemia by intracoronary ECG using convolutional neural networks. *Plos one*, *16*(6), e0253200.

[3] Ogrezeanu, I., Stoian, D., Turcea, A., & Itu, L. M. (2020, October). Deep learning based myocardial ischemia detection in ECG signals. In *2020 24th International Conference on System Theory, Control and Computing (ICSTCC)* (pp. 250-253). IEEE.

[4] Papaloukas, C., Fotiadis, D. I., Likas, A., & Michalis, L. K. (2002). An ischemia detection method based on artificial neural networks. *Artificial intelligence in medicine*, *24*(2), 167-178.

[5] Robotics.org.za, "AD8232 Heart Rate Monitor Kit," Robotics Online Store, [Online]. Available: https://www.robotics.org.za/AD8232-KIT. [Accessed: Aug. 25, 2025].

[6] ECG Monitoring using AD8232 ECG Sensor and Arduino," How2Electronics, [Online]. Available: https://how2electronics.com. [Accessed: Aug. 25, 2025].

[7] ECG Monitoring with AD8232 ECG Sensor & Arduino," Electronics Go, [Online]. Available: https://electronics-go.com/articles/ecg-monitoring-with-ad8232-ecg-sensor-arduino/. [Accessed: Aug. 25, 2025].

[8] Analog Devices, "AD8232: Heart Rate Monitor Front End," Datasheet, 2012. [Online]. Available: https://www.analog.com/media/en/technical-documentation/data-sheets/AD8232.pdf. [Accessed: Aug. 25, 2025].

[9] M. S. Manikandan and K. P. Soman, Biomedical Signal Processing: Principles and Techniques. New Delhi: PHI Learning Pvt. Ltd., 2012.

[10] J. G. Webster, Medical Instrumentation: Application and Design, 4th ed. Hoboken, NJ: John Wiley & Sons, 2009.

Syrian Arab Republic
Damascus University
Faculty of Mechanical and Electrical Engineering
Department of Biomedical Engineering

DL – CIDEA

Deep Learning for Cardiac Ischemia Detection

via ECG Analysis

-Fourth Year Project-

By:

Mouhammad Sheikh Hussein **Mouhammad Abd AL-Rahman**
Saeed Mouhammad Ezziah **Hiba Khalid Tayb**

Supervised By:

Prof. Hani Amasha

2025−2024